CLIP 家族架构详解

双塔对比学习奠基之作 · 400M 网络图文对 · 对称 InfoNCE · 零样本迁移范式

依据：transformers 源码（本机 editable）E:\transformers\src\transformers\models\clip\（版本 5.23.0.dev0，本文档所有行号/字段均以此为准），官方论文 arXiv:2103.00020（Radford et al., 2021, PMLR），HF 模型卡交叉验证。CLIP 是 OpenAI 2021 年的双塔视觉语言模型：图像与文本各自编码到同一向量空间，用对比学习对齐，以 4 亿网络图文对为监督，训练出可零样本迁移的视觉模型。标注「待确认」处未编造。

1 一句话定位

CLIP（Contrastive Language-Image Pre-training）核心主张：图像和文本各自编码到同一个向量空间，用对比学习对齐，以 4 亿（400M）网络图文对为监督，训练出可零样本迁移的视觉模型——零样本分类、图文检索、图文相似度的标准范式。现代多模态 LLM 的视觉塔大多直接或间接继承自 CLIP。

2 源码模块与类关系

文件	职责
configuration_clip.py	CLIPTextConfig / CLIPVisionConfig / CLIPConfig
modeling_clip.py	全部模型类（文本塔 / 视觉塔 / 双塔 / 任务头）
tokenization_clip.py	CLIP 专用 BPE 分词器（49408 词表）
processing_clip.py	Processor（分词 + 图像预处理合一）
image_processing_clip.py / image_processing_pil_clip.py	图像 resize → center crop → 归一化
convert_clip_original_pytorch_to_hf.py	OpenAI 官方权重 → HF 格式

表 1：CLIP 源码文件分工

2.1 modeling_clip.py 类清单

类	行号	职责
CLIPVisionEmbeddings	:138	patch 化嵌入 + CLS + 位置编码
CLIPTextEmbeddings	:221	token + 位置编码（因果注意力的文本嵌入）
CLIPAttention / CLIPMLP	:280 / :338	注意力 / FFN（激活 quick_gelu）
CLIPEncoderLayer	:353	单层 Transformer（继承 GradientCheckpointingLayer）
CLIPEncoder	:446	12 层编码器
CLIPTextModel	:485	文本塔（池化取 [EOS] 状态）
CLIPVisionModel	:585	视觉塔（池化取 [CLS] 状态）
CLIPModel	:651	双塔完整模型（对比损失 + 相似度）
CLIPTextModelWithProjection	:826	文本塔 + 投影层（检索用）
CLIPVisionModelWithProjection	:890	视觉塔 + 投影层（检索用）
CLIPForImageClassification	:959	分类头（HF 为有监督微调加的线性头，非原论文结构）

表 2：modeling_clip.py 类清单

3 配置字段（configuration_clip.py）

3.1 文本塔 CLIPTextConfig（:27）

字段	默认值	说明
model_type	clip_text_model	—
vocab_size	49408	BPE 词表（含 startoftext/endoftext 等特殊 token）
hidden_size	512	—
intermediate_size	2048	—

字段	默认值	说明
projection_dim	512	投影目标维度
num_hidden_layers	12	—
num_attention_heads	8	—
max_position_embeddings	77	文本最长 77 token
hidden_act	quick_gelu	CLIP 特有激活
bos / eos / pad	49406 / 49407 / 1	特殊 token

表 3：文本塔配置字段

3.2 视觉塔 CLIPVisionConfig（:77）

字段	默认值	说明
model_type	clip_vision_model	—
hidden_size	768	—
intermediate_size	3072	—
projection_dim	512	—
num_hidden_layers	12	—
num_attention_heads	12	—
image_size	224	输入分辨率
patch_size	32	→ 7×7 = 49 patch + CLS = 50 token
hidden_act	quick_gelu	—

表 4：视觉塔配置字段

3.3 双塔 CLIPConfig（:122）

字段	默认值	说明
text_config / vision_config	子配置	可分别覆盖
logit_scale_init_value	2.6592	可学习温度初始值 ≈ ln(1/0.07)

表 5：双塔配置字段

4 端到端双塔架构总览

视觉塔把 224×224 切成 7×7=49 个 32×32 patch + CLS → 12 层双向 Transformer → 池化取 [CLS]；文本塔 BPE 分词 → 12 层因果 Transformer（GPT-2 式）→ 池化取 [EOS]。两塔投影到 512 维公共空间做对比。

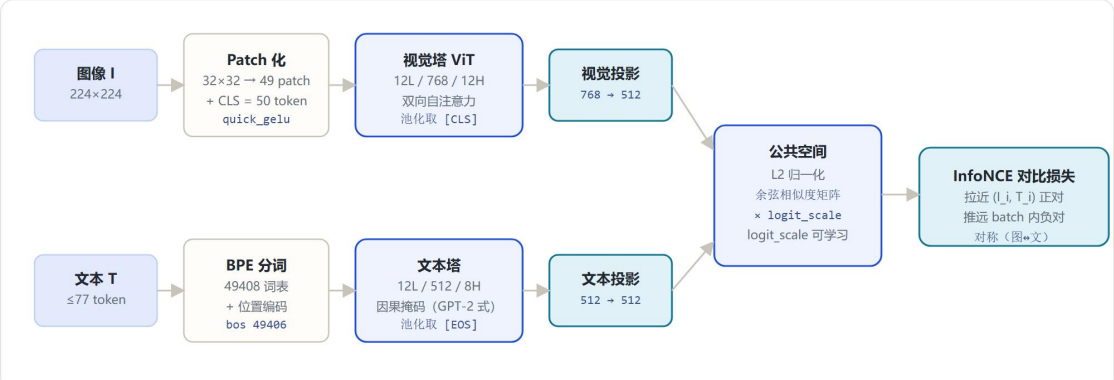


图 1：CLIP 端到端双塔架构总览

5 核心机制（对照代码）

5.1 双塔各自编码

视觉塔（CLIPVisionModel :585）：CLIPVisionEmbeddings 把 224×224 切成 32×32 patch（49 个）拼上 CLS token → 12 层双向 Transformer → 池化取 [CLS] 状态（:630 docstring「pooled CLS states」）。

文本塔（CLIPTextModel :485）：BPE 分词 → 位置编码 → 12 层因果 Transformer（GPT-2 式）→ 池化取 [EOS]（最后一个 token）状态（:524 docstring「pooled (EOS token) states」）。

5.2 投影与相似度（CLIPModel :651）

```
image_embeds = visual_projection(pooler_output)   # 768 → 512
text_embeds  = text_projection(pooler_output)     # 512 → 512
```

两者 `L2` 归一化 → 余弦相似度矩阵 `×` `logit_scale`

logit_scale 是可学习参数，初始 2.6592 ≈ ln(1/0.07)（对比 OpenAI 原实现）。

5.3 对比损失（InfoNCE）

对 batch 内每张图：拉近正样本对 (I_i, T_i)，推远 batch 内其余文本 (I_i, T_j) 作为负样本；对称地也以文本为锚。不做显式 hard-negative 挖掘，靠大 batch 提供负样本。

5.4 图像预处理

image_processing_clip.py：resize（保持比例）→ center_crop(224) → ImageNet 均值/方差归一化——与训练口径严格一致。

6 训练方法（论文层面）

要素	要点
数据	4 亿（400M）从互联网收集的图文对，天然带噪声但规模巨大
目标	对称对比损失（InfoNCE），batch 极大（论文以 32768 级 batch 训练）
可学习温度	logit_scale 随训练调整，避免人为设定 softmax 温度
零样本迁移	分类时把类别名拼成「a photo of a {label}」模板输入文本塔，取与图像特征相似度最高者

表 6：CLIP 训练方法要点

7 模型家族速览

变体	视觉塔	说明
openai/clip-vit-base-patch32	ViT-B/32	默认配置口径
openai/clip-vit-base-patch16	ViT-B/16	—
openai/clip-vit-large-patch14	ViT-L/14	—
openai/clip-vit-large-patch14-336	ViT-L/14@336	336 分辨率微调
RN 系列	RN50 / RN101 / RN50x4 / RN50x16 / RN50x64	ResNet 视觉塔变体（EfficientNet 缩放）

表 7：CLIP 家族检查点

一分钟结论

维度	要点
架构	视觉塔 ViT-B/32（12L/768/12H）+ 文本塔 Transformer（12L/512/8H）双塔
对齐	投影到 512 维公共空间，L2 归一化 + 余弦相似度 × logit_scale
损失	对称 InfoNCE 对比损失，正对拉近 / 负对推远
池化	视觉取 [CLS]，文本取 [EOS]
预训练数据	4 亿网络图文对
代码入口	CLIPModel / CLIPTextModel / CLIPVisionModel / *WithProjection / CLIPForImageClassification

表 8：一分钟结论

与多模态 LLM 的关系：LLaVA、BLIP-2、InstructBLIP、MiniGPT-4 等第一代多模态 LLM 直接借用 CLIP 视觉塔（通常 ViT-L/14@336）作为视觉编码器；SigLIP（同仓库 models/siglip/）用逐对 sigmoid 损失替代 CLIP 的 softmax 对比损失；BLIP 的 ITC 目标即 CLIP 式对比。Qwen2-VL / InternVL 等自研视觉塔虽非 CLIP 实现，但同属「图文对比预训练视觉编码器」谱系，CLIP 是这条线的原点。

8 来源

[1] 论文：Learning Transferable Visual Models From Natural Language Supervision，arXiv:2103.00020（Radford et al., 2021, PMLR）

[2] HF 模型卡：openai/clip-vit-base-patch32 等

[3] transformers 源码（本机 editable）：src/transformers/models/clip/（5.23.0.dev0）

待确认/边界：论文训练超参（batch、epochs）与各变体精确参数以论文/模型卡为准；CLIPForImageClassification 是 HF 为有监督微调额外加的线性头，不属于原论文结构。