ChatGLM2 / ChatGLM3 家族架构详解

28 层 · hidden 4096 · MQA(32Q/2KV) · RMSNorm · SwiGLU · 1D-RoPE

依据：官方 config（hf-mirror/ModelScope）+ transformers 源码 （E:\transformers）+ 官方论文/model card。所有数值按 config 实际取值与官方论文逐项复算并标注来源。

徽标：model_type=chatglm · 入口类 ChatGLMModel · trust_remote_code

徽标：28 层 · hidden 4096 · 32 Q 头 / 2 KV 组（MQA）· kv_channels=128

徽标：RMSNorm （post_layer_norm） · SwiGLU FFN 13696 · 1D-RoPE （original_rope=true）

徽标：padded 词表 65024 · ChatGLM2 上下文 32768 / ChatGLM3 config seq_length 8192

本页以 HF THUDM/chatglm2-6b 与 THUDM/chatglm3-6b 官方 config.json（经 hf-mirror 拉取，分别留档 _tools/_cfgpull/chatglm2_6b.config.json 与 chatglm3_6b.config.json）为唯一依据。逐字段比对后确认：ChatGLM2-6B 与 ChatGLM3-6B 的架构超参数完全一致（hidden 4096、28 层、32 头、kv_channels 128、MQA group 2、ffn 13696、padded_vocab 65024、rmsnorm、post_layer_norm、original_rope、add_qkv_bias 等全部相同），唯一差异是 seq_length 字段（ChatGLM2=32768，ChatGLM3=8192）。因此按规格合并为同一目录、内部两节区分。两代均需 trust_remote_code 加载官方 configuration_chatglm.py / modeling_chatglm.py（transformers v5 无原生 chatglm 模块）。

1 家族全景：两代 config 逐字段对照

下表同一行列出两代 config 的取值；「相同」表示两版该字段逐字一致。

config 字段	ChatGLM2-6B	ChatGLM3-6B	说明
model_type	chatglm	chatglm	相同
architectures	ChatGLMModel	ChatGLMModel	相同
hidden_size	4096	4096	相同
num_layers	28	28	相同
num_attention_heads	32	32	Q 头数相同
kv_channels	128	128	每头维度
multi_query_attention	true	true	开启 MQA/GQA
multi_query_group_num	2	2	32 Q 头共享 2 组 KV
ffn_hidden_size	13696	13696	相同（≈10/3·4096）
rmsnorm	true	true	RMSNorm 取代 LayerNorm

config 字段	ChatGLM2-6B	ChatGLM3-6B	说明
post_layer_norm	true	true	Post-LN 布局
original_rope	true	true	标准 1D RoPE（去 2D）
add_qkv_bias	true	true	仅 QKV 带 bias
add_bias_linear	false	false	其余线性层去偏置
attention_softmax_in_fp32	true	true	softmax fp32
padded_vocab_size	65024	65024	相同
tie_word_embeddings	false	false	相同
layernorm_epsilon	1e-5	1e-5	相同
seq_length	32768	8192	唯一差异字段
eos_token_id	2	2	相同
pad_token_id	0	0	相同
torch_dtype	float16	float16	相同

要点：两代架构数字完全同构，区别集中在训练序列长度字段与后训练能力（ChatGLM3 起支持 function call、代码解释器、Agent 任务）。config 字段级证据见两份留档文件。

2 端到端数据流总览

输入 token（eos=2/pad=0）→ 词嵌入（padded_vocab 65024，解绑 LM Head）→ 28 个 GLM Block（RMSNorm + MQA 注意力[32Q/2KV] + 1D-RoPE + SwiGLU FFN 13696）→ 最终 post RMSNorm → LM Head。

2.1 架构图

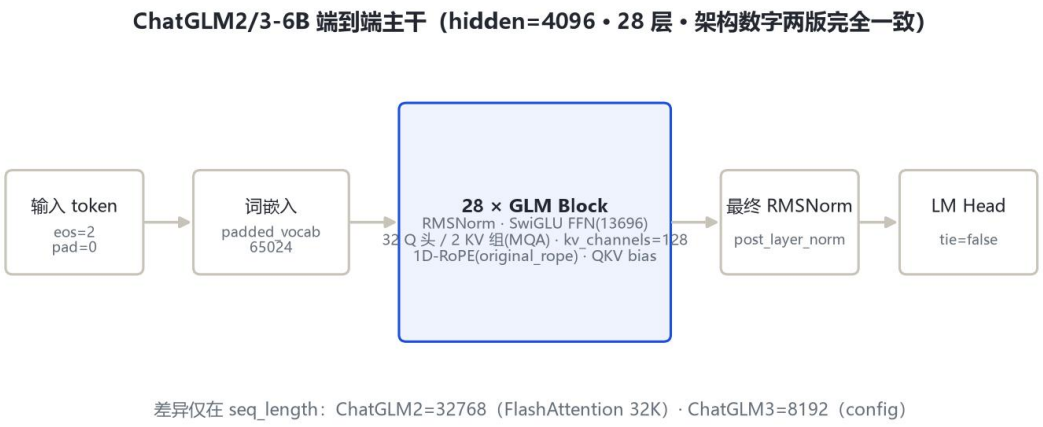


图 1：架构图：端到端主干（两代同构）

全主干：词嵌入 → 28×(MQA 注意力 + SwiGLU) → 最终 RMSNorm → softmax。与 ChatGLM-6B 的差别：去 2D-RoPE、换 RMSNorm+SwiGLU、引入 MQA、上下文显著拉长。

3 解码层解剖

```
# ChatGLM2/3 Block（依据官方 modeling_chatglm.py 传统，trust_remote_code）
x = RMSNorm(x)
# MQA 注意力：32 个 Q 头共享 2 组 KV，QKV 带 bias
a = SelfAttention(QKV_bias(x), kv_groups=2, rope=1d)
x = x + a                          # post_layer_norm 残差
x = RMSNorm(x)
# SwiGLU 前馈，ffn_hidden_size=13696
f = SwiGLU(x)
x = x + f
```

rmsnorm=true 、 post_layer_norm=true ： 归一化由 ChatGLM-6B 的 LayerNorm 换成 RMSNorm，布局为 Post-LN。ffn_hidden_size=13696 ≈ 10/3 × 4096（与 GLM-4 论文所述「为补偿 GQA 减参而把 FFN 提到 10/3·hidden」的口径一致）。

4 核心机制

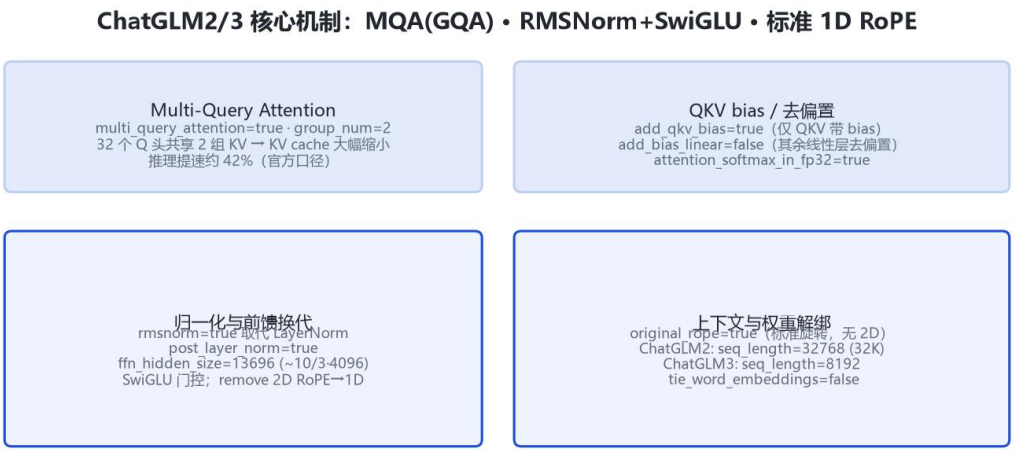


图 2：架构图：核心机制（MQA · RMSNorm+SwiGLU · 1D-RoPE）

4.1 ① Multi-Query Attention（GQA）

multi_query_attention=true 、 multi_query_group_num=2： 32 个 Q 头只配 2 组 KV 头。KV cache 大小降为 1/16，官方综述称推理速度提升约 42%。

```
Q: 32 头 × 128 = 4096
K,V: 2 组 × 128 = 256  (repeat_kv 到 32 头后做注意力)
```

4.2 ② RMSNorm + SwiGLU + 去偏置

rmsnorm=true 取代 LayerNorm；add_qkv_bias=true 仅注意力 QKV 投影保留 bias，add_bias_linear=false 其余线性层去偏置（官方综述称此举轻微改善长度外推）。attention_softmax_in_fp32=true 保证数值稳定。

4.3 ③ 1D 标准 RoPE 与上下文长度

original_rope=true：移除 ChatGLM-6B 的 2D-RoPE，回到标准一维旋转位置编码。上下文：ChatGLM2 config seq_length=32768（借 FlashAttention 扩到 32K）；ChatGLM3 config seq_length=8192。官方综述称两代上下文均做到 32K 级，config 的 seq_length 为训练序列长度口径。

5 注意力机制

项	ChatGLM2/3 取值
Q 头数	32
KV 组数	2（MQA/GQA，multi_query_group_num=2）
kv_channels（head_dim）	128
位置编码	1D-RoPE（original_rope=true）
QKV bias	true（仅 QKV 带 bias）
softmax 精度	fp32

$$\text{Attn}(Q,K,V)=\text{softmax_fp32}((QK^{\wedge T})/(\sqrt{(d_k)})+\text{mask})V,\ K,V \text{ 仅 2 组}$$

与 ChatGLM-6B（32 头全 MHA、2D-RoPE、LayerNorm）相比，ChatGLM2/3 在注意力上的三处变更：MQA 减 KV、去 2D-RoPE、换 RMSNorm。

6 特殊 Token 与词表

项	取值
padded_vocab_size	65024
eos_token_id	2
pad_token_id	0
tie_word_embeddings	false（embedding 与 LM Head 解绑）

词表由 ChatGLM-6B 的 130528 降到 65024（padded），并切换 tokenizer。ChatGLM3 起在对话模板层引入 function call / Agent 相关角色标记（架构字段之外，由 chat template 定义）。

7 演进视角：ChatGLM-6B → ChatGLM2 → ChatGLM3

维度	ChatGLM-6B	ChatGLM2-6B	ChatGLM3-6B
层数 / hidden	28 / 4096	28 / 4096	28 / 4096
注意力	MHA 32 头	MQA 32Q/2KV	MQA 32Q/2KV
位置编码	2D-RoPE	1D-RoPE(original)	1D-RoPE
归一化	LayerNorm	RMSNorm	RMSNorm
FFN	inner 16384	ffn 13696 (SwiGLU)	ffn 13696
上下文(config)	2048	32768	8192
词表	130528	65024	65024
tie embeddings	—	false	false

演进要点：① ChatGLM2 是架构换代——去 2D-RoPE、LayerNorm→RMSNorm、引入 MQA、FFN 换 SwiGLU(13696)、上下文 2K→32K；② ChatGLM3 架构数字与 ChatGLM2 完全同构，升级集中在数据/后训练（42 个基准登顶、function call、代码解释器、Agent）；③ config 唯一字段差异 seq_length（32768 vs 8192）。

8 来源

1. 远端官方 config：HF THUDM/chatglm2-6b（hf-mirror，2026-10-31）

https://hf-mirror.com/THUDM/chatglm2-6b/resolve/main/config.json

本地留档：E:\transformers\bayon-note\GLM\chatglm2_3_tools_cfgpull\chatglm2_6b.config.json

2. 远端官方 config：HF THUDM/chatglm3-6b（hf-mirror，2026-10-31）

https://hf-mirror.com/THUDM/chatglm3-6b/resolve/main/config.json

本地留档：E:\transformers\bayon-note\GLM\chatglm2_3_tools_cfgpull\chatglm3_6b.config.json

3. 官方仓库 THUDM/ChatGLM2-6B / ChatGLM3（modeling_chatglm.py，trust_remote_code）

https://github.com/THUDM/ChatGLM2-6B；https://github.com/THUDM/ChatGLM3

4. ChatGLM 家族综述论文（MQA 提速 42%、FlashAttention 32K、RMSNorm/SwiGLU/GQA 架构叙事，arXiv:2406.12793）

https://arxiv.org/abs/2406.12793

5. transformers 本地模块核验：E:\transformers\src\transformers\models\glm\configuration_glm.py（model_type=glm 对应 GLM-4-9B，非 chatglm）

标注约定：两代 config 逐字段比对，差异仅 seq_length；实现细节以官方 trust_remote_code 文件为准。ChatGLM3 config seq_length=8192 与综述「32K」口径差异已在 §4.3 说明。访问与核验日期：2026-10-31。

页脚：ChatGLM2/3 家族架构详解 · 数据来源：远端官方 config（hf-mirror）+ 官方仓库 + arXiv 2406.12793 · 仅供技术学习与论文研究