GLM-4 家族架构详解

Glm4ForCausalLM · GLM-4-9B / GLM-4-32B-0414（Dense 文本）· GQA 32Q/2KV · partial rotary 0.5 · 4×RMSNorm 双残差

依据：官方 config（hf-mirror/ModelScope）+ transformers 源码 （E:\transformers）+ 官方论文/model card。所有数值按官方 config 实参与源码 forward 路径逐项复算并标注来源；无法核实者标注「待确认」。

徽标：入口类 ChatGLMModel （9B 原始发布，trust_remote_code）→ 原生 Glm4ForCausalLM（transformers 现代移植，model_type=glm4）
徽标：GQA 32Q / 2KV （9B）· head_dim 128 · partial rotary 0.5 （仅前 64 维旋转，ChatGLM 血统）
徽标：4×RMSNorm「pre+post」双残差块（post_layer_norm）· 融合 gate_up 的 SiGLU
徽标：词表 151552 · 9B 基座 seq 8192（推理扩 128K）· tie_word_embeddings=False
徽标：GLM-4-32B-0414 为 Dense 61 层（hidden 6144），非 MoE；QKV bias 在 9B 为 true、32B-0414 为 false

本页以官方 config（2026-10-31 经 hf-mirror 拉取留档于 _tools/_cfgpull/）与 transformers 源码（本地 E:\transformers，models\glm4\configuration_glm4.py / modeling_glm4.py）为唯一依据。GLM-4-9B 的 2024 原始发布以 model_type=chatglm、ChatGLMModel + auto_map 远程代码分发；transformers v5 的原生 glm4 模块是其官方现代移植，默认配置与 9B 逐项对齐。所有数字均标注来源（config 字段或源码文件:行号）。

1 家族全景：GLM-4 两档 Dense 规格对照

GLM-4 文本代有两档：GLM-4-9B（2024-01 首发，原始 chatglm 远程 config）与 GLM-4-32B-0414（2025-04 升级，原生 glm4 config）。二者主干一致（4×RMSNorm 双残差、GQA、partial rotary、SiGLU），仅维度、层数与个别开关随尺寸变化。

1.1 文本塔核心超参数

字段	GLM-4-9B（2024-01）	GLM-4-32B-0414（2025-04）

字段	GLM-4-9B（2024-01）	GLM-4-32B-0414（2025-04）
入口类 / model_type	ChatGLMModel（远程代码，chatglm）	Glm4ForCausalLM（glm4）
形态	纯文本 Dense	纯文本 Dense
hidden_size	4096	6144
num_hidden_layers	40	61
num_attention_heads (Q)	32	48
num_key_value_heads (KV)	2（multi_query_group_num=2）	2
head_dim	128（kv_channels=128）	128
intermediate_size（SiGLU FFN）	13696（ffn_hidden_size）	23040
vocab_size	151552（padded_vocab_size）	151552
partial_rotary_factor	0.5（original_rope）	0.5
rope_theta	10000（original_rope 默认）	10000.0
max_position_embeddings	131072（原生 port）；远程 config seq_length=8192 为基座训练长度，推理扩 128K	32768
attention_bias（QKV 偏置）	true（add_qkv_bias=true）	false
tie_word_embeddings	false	false
rms_norm_eps	1.5625e-6（layernorm_epsilon）	1e-5
hidden_act	silu（SiGLU）	silu

要点：① 两档均为 Dense（config 无 n_routed_experts / moe 字段）；GLM-4-32B-0414 的 architectures=Glm4ForCausalLM、model_type=glm4 证实其非 MoE——MoE 是 GLM-4.5 才引入（见 glm_4_5）。② GQA 分组 9B 为 32/2=16:1、32B 为 48/2=24:1。③ QKV 偏置是两档唯一的注意力开关差异：9B 远程 config add_qkv_bias=true（原生 port attention_bias=True），32B-0414 改为 attention_bias=false。④ partial_rotary_factor=0.5 在两档均显式给出。

1.2 部署与上下文规格

字段	GLM-4-9B	GLM-4-32B-0414
官方参数量	≈9B	≈32B（Dense）
基座 seq_length	8192（远程 config）；经 RoPE 外推支持 128K	32768
pad / eos	pad=151329; eos=[151329,151336,151338]	pad=151329; eos=[151329,151336,151338]
torch_dtype	bfloat16	bfloat16

2 端到端数据流总览

文本 token → 词嵌入（Embedding，不与 LM Head 绑定）→ N 个 GLM-4DecoderLayer（4×RMSNorm 双残差块：注意力子层 + SiGLU FFN 子层）→ 最终 RMSNorm → LM Head（解绑）。GLM-4 为纯文本代，无视觉塔（视觉变体 GLM-4V-9B 见 glm_4v）。

2.1 架构图

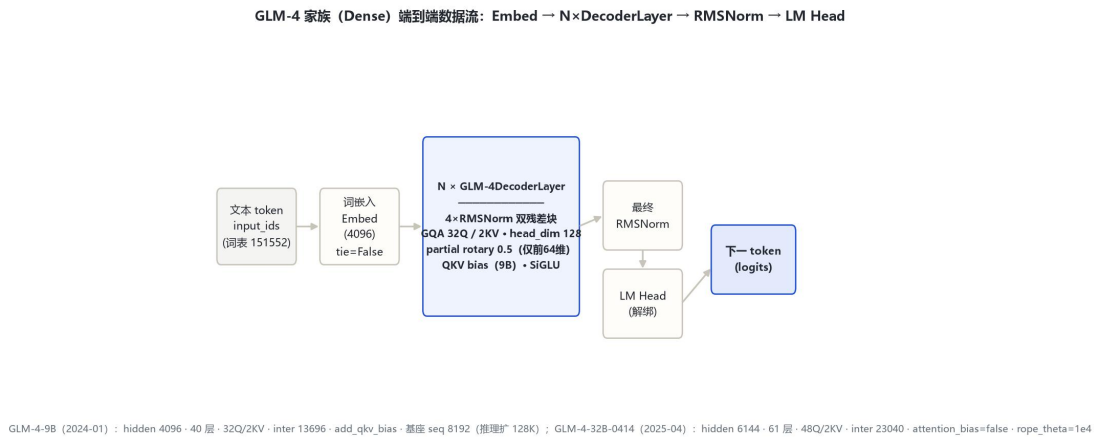


图 1：架构图：GLM-4 家族端到端数据流总览

全家族统一主干：Embedding → N×DecoderLayer → 最终 RMSNorm → LM Head；差异集中在 hidden、层数、Q 头数与 QKV bias 开关。

3 解码层解剖：4×RMSNorm「pre+post」双残差块

Glm4DecoderLayer（modeling_glm4.py:66-109）含两组残差子层，每个子层用 前置 + 后置两个 RMSNorm（post_layer_norm=true 的 ChatGLM 传统，区别于 Qwen3 的单 RMSNorm 前置）。两层共享此结构。

3.1 架构图

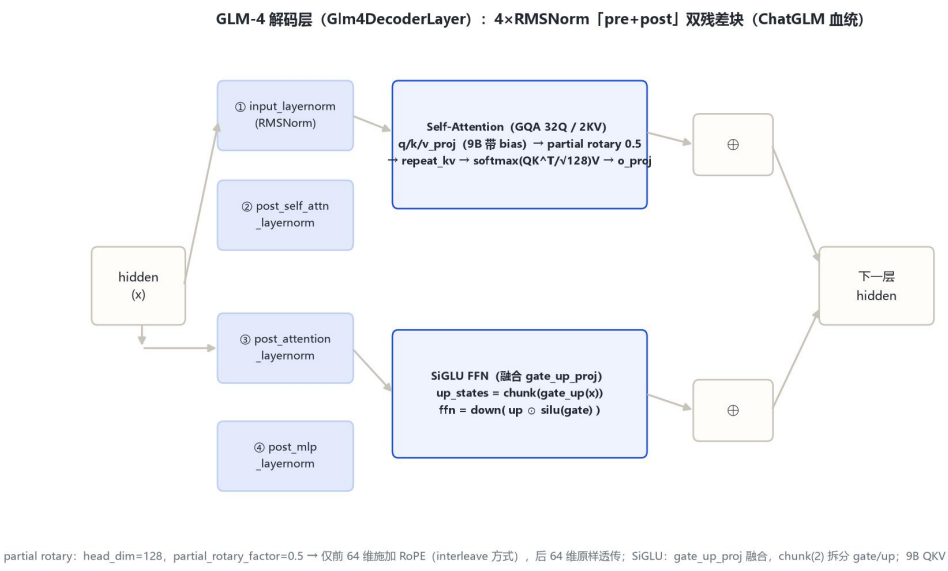


图 2：架构图：GLM-4 解码层（4×RMSNorm 双残差）与核心机制

```
Glm4DecoderLayer.forward（modeling_glm4.py:88-109）：
  residual = hidden_states
  hidden_states = input_layernorm(hidden_states)        # ① RMSNorm(hidden)
  hidden_states, _ = self_attn(hidden_states, ...)      # GQA + partial
rotary 0.5
  hidden_states = post_self_attn_layernorm(hidden_states)# ② RMSNorm
  hidden_states = residual + hidden_states              # ⊕1
  residual = hidden_states
  hidden_states = post_attention_layernorm(hidden_states)# ③ RMSNorm
  hidden_states = self.mlp(hidden_states)               # SiGLU（融合
gate_up）
  hidden_states = post_mlp_layernorm(hidden_states)      # ④ RMSNorm
  hidden_states = residual + hidden_states              # ⊕2
  return hidden_states
```

与 Qwen3 的「单 RMSNorm 前置（pre-norm）」不同，GLM-4 每个子层在残差相加前对子层输出再归一一次（post_self_attn_layernorm / post_mlp_layernorm），共 4 个 RMSNorm/层（modeling_glm4.py:73-76）。

4 核心机制：partial rotary · GQA · 4×RMSNorm · SiGLU

4.1 ① 部分旋转位置编码（partial_rotary_factor=0.5）

GLM-4 继承 ChatGLM 的 partial rotary：head_dim=128 中只有前一半（64 维）施加 RoPE，后一半（64 维）原样透传。Glm4RotaryEmbedding.compute_default_rope_parameters 中旋转维度 dim = head_dim × partial_rotary_factor = 128 × 0.5 = 64（modeling_glm4.py:290-292）。

inv_freq_i = base^(-2i/dim), i=0,…,dim/2-1, dim=64

```
apply_rotary_pos_emb（modeling_glm4.py:178-192）:
  cos/sin 先 repeat_interleave(2, dim=-1)          # interleave 排列
  q_rot, q_pass = q[..., :rotary_dim], q[..., rotary_dim:]   # 前 64 / 后
64
  q_embed = (q_rot*cos) + (rotate_half(q_rot)*sin)
  q_embed = cat([q_embed, q_pass], dim=-1)         # 后 64 维不旋转
```

与「全维度 RoPE」（Qwen3）不同，GLM-4 只旋转 64/128 维；base（rope_theta）两档均为 10000。原生 port 以 partial_rotary_factor 默认值 0.5 保持向后兼容（configuration_glm4.py:77）。

4.2 ② GQA 与 KV 压缩（16:1 / 24:1）

Glm4Attention 中 num_key_value_groups = num_attention_heads / num_key_value_heads（modeling_glm4.py:204），运行时 repeat_kv 把 K/V 从 KV 头复制到 Q 头数（modeling_glm4.py:112-121, 134-135）。

4.3 ③ 4×RMSNorm（pre+post）

Glm4RMSNorm（modeling_glm4.py:310-328）先 fp32 归一 hidden × rsqrt(mean(x²)+eps)，再乘可学习权重 γ。每子层前置一个、后置一个 RMSNorm（见 §3）。eps：9B=1.5625e-6、32B-0414=1e-5。

4.4 ④ 融合 gate_up 的 SiGLU

Glm4MLP（modeling_glm4.py:48-63）用单个 gate_up_proj 一次性投影到 2×intermediate_size，再 chunk(2) 拆出 gate/up：

$$FFN(x)=down(up\odot silu(gate)),\ [gate,up]=chunk_2(gate_up_proj(x))$$

9B intermediate=13696、32B=23040；三个投影全部 bias=False（modeling_glm4.py:53-54）。

5 注意力机制：GQA · partial rotary · QKV bias

5.1 GQA KV 头分配（repeat_kv）

尺寸	Q 头数	KV 头数	GQA 分组	head_dim	Q 投影输出维
GLM-4-9B	32	2	16:1	128	32×128=4096=hidden
GLM-4-32B-0414	48	2	24:1	128	48×128=6144=hidden

5.2 注意力核心与缩放

$$Attn(Q,K,V)=softmax((QK^{\wedge T})/(\sqrt{(128)})+mask)V$$

```
Glm4Attention.forward（modeling_glm4.py:209-258）：
  q_proj / k_proj / v_proj  bias=config.attention_bias   # 9B=True，32B-0414=False
  o_proj bias=False
  scaling = head_dim ** -0.5 = 128**-0.5                  # line 205
  query/key 经 apply_rotary_pos_emb（partial rotary 0.5）
  repeat_kv(K,V) → softmax(QK^T*scaling, fp32)V → o_proj
```

注意力缩放固定 head_dim^-0.5（modeling_glm4.py:205）。9B 远程 config 的 apply_query_key_layer_scaling=true 是旧版开启 QK 缩放的开关，原生 port 统一为 head_dim^-0.5。

6 特殊 Token 与词表布局

token	ID	含义	来源
pad_token_id	151329	填充	config 顶层
eos_token_id	[151329, 151336, 151338]	序列结束（多终止符）	config；configuration_glm4.py:79
vocab_size	151552	词表大小	config 顶层（padded_vocab_size）

token	ID	含义	来源
boi / eoi	151339 / 151340	图像块起止（仅 GLM-4V-9B，见 glm_4v）	glm4v config

词表 vocab_size=151552（GLM 系沿用，与 Qwen 的 151936 不同）。GLM-4 文本代无额外思维标记——长思维链推理是 GLM-Z1（glm_z1）才引入的训练目标，架构不变。

7 演进视角：ChatGLM-3 → GLM-4 → GLM-4.5

早期代（ChatGLM-1/2/3、GLM-130B）由同项目另一执行者负责；本表只列与 GLM-4 相邻、可从官方 config/源码核实的锚点。

维度	ChatGLM-3（基线，远程代码）	GLM-4（本代 Dense）	GLM-4.5（下一大代，见 glm_4_5）
形态	Dense	Dense（9B / 32B-0414）	MoE（355B-A32B，160 专家）
GQA	MQA / 小 KV 组	GQA 32Q/2KV（16:1）	GQA 96Q/8KV
归一化	RMSNorm + post_layer_norm	同（4×RMSNorm 双残差）	简化为 2×RMSNorm 前置 + QK-Norm
partial rotary	有	有（0.5）	有（0.5）+ use_qk_norm
FFN	GLU	融合 gate_up SiGLU	SiGLU + 路由专家 + 共享专家
MTP / 推理	无	无	num_nextn_predict_layers=1（MTP）

GLM-4 的主线定位：① 把 ChatGLM 系的 4×RMSNorm 双残差、partial rotary、GQA 定型为 Dense 两代（9B 首发、32B-0414 升级）；② 词表固定 151552；③ 为 GLM-4.5 的 MoE 化提供文本主干基础。GLM-4.5 在同主干上换 MoE、加 QK-Norm 与 MTP（详见 glm_4_5）。

8 来源

1. 官方 config（GLM-4-9B，远程 chatglm 格式，2026-10-31 经 hf-mirror 拉取留档）

zai-org/glm-4-9b（model_type=chatglm / ChatGLMModel；hidden 4096 / 40 层 / 32 头 / multi_query_group_num=2 / kv_channels 128 / ffn 13696 / vocab 151552 / add_qkv_bias / original_rope / post_layer_norm / rmsnorm / seq_length 8192 / tie=false）

zai-org/glm-4-9b-chat（对话版，同构）

2. 官方 config（GLM-4-32B-0414，原生 glm4 格式，留档于 glm_4/_tools/_cfgpull/）

zai-org/GLM-4-32B-0414 （Glm4ForCausalLM； hidden 6144 / 61 层 / 48Q·2KV / head_dim 128 / inter 23040 / partial rotary 0.5 / rope_theta 1e4 / max 32768 / attention_bias=false / tie=false）

3. transformers 源码 configuration_glm4.py（本地 E:\transformers）

vocab 151552(56) / hidden 4096(57) / inter 13696(58) / layers 40(59) / heads 32(60) / kv_heads 2(61) / head_dim 128(62) / max_position 131072(65) / rms_eps 1.5625e-6(67) / tie=false(69) / pad 151329(71) / attention_bias=true(74) / eos[...](79) / partial_rotary_factor=0.5 默认(77)

4. transformers 源码 modeling_glm4.py

Glm4MLP gate_up 53 / chunk 60 / SiGLU 61； DecoderLayer 66-109 （4 RMSNorm 73-76， forward 88-109）； repeat_kv 112-121； apply_rotary 156-193 （interleave 178-179，partial 182-184）； Attention 196-258 （head_dim 203，groups 204，scaling 205，QKV bias 209-217）； RotaryEmbedding 261-307 （dim=head×partial 292）； RMSNorm 310-328；Model 351-421；ForCausalLM lm_head 435

5. GLM-4 模型卡片与技术报告

https://huggingface.co/zai-org/glm-4-9b （GLM-4 系列发布，9B/32B/多模态规格与 128K 上下文口径）； 智谱 BigModel 开放平台 GLM-4 发布公告

标注约定： [S:n]=modeling_glm4.py 行号； config 来源标注「远端官方 config：<repo> 」+ 拉取日期 2026-10-31 。GLM-4-9B 远程 config 字段名 （kv_channels / multi_query_group_num / ffn_hidden_size / num_layers / padded_vocab_size）与原生 glm4 字段名 （head_dim / num_key_value_heads / intermediate_size / num_hidden_layers / vocab_size）的对应关系已在 §1 表格逐格标注。GLM-4-9B 基座 seq_length=8192、推理外推到 128K 为官方 card 口径。访问与核验日期：2026-10-31。

页脚：GLM-4 家族架构详解 · 数据来源：远端官方 config（hf-mirror）+ transformers 源码（E:\transformers）+ 官方 model card · 仅供技术学习与论文研究