InternVL 2.0 家族架构详解

InternVLChatModel · ViT–MLP–LLM · 1B–108B · 动态高分辨率

依据：本地 E:\models\model\InternVL2-1B\config.json 全文逐字段核对 + 本地 transformers 源码（E:\transformers\src\transformers\models\internvl\）+ InternVL2 官方博客（2024-07-02）与官方文档。所有数值以 config 原文与官方来源为准，已联网核实处逐条标注。

2024-07 发布 · 多模态大模型 · 视觉塔连续学习 · Progressive Scaling Strategy

1 家族全景与本地 config 对照

InternVL 2.0 延续 InternVL 1.5 的 ViT–MLP–LLM 范式：视觉塔（InternViT）→ 像素洗牌（pixel shuffle）→ MLP 投影层 → 大语言模型。家族覆盖 1B（端侧）到 108B，按尺寸搭配两种视觉塔规格与七种语言底座。下表逐成员列出视觉塔与语言底座（官方文档口径）。

1.1 家族成员：视觉塔与语言底座对照

模型	视觉塔	语言底座	总参数量	ViT / MLP / LLM
InternVL2-1B	InternViT-300M-448px	Qwen2-0.5B-Instruct	约 1B	本地 config 见 §1.2
InternVL2-2B	InternViT-300M-448px	internlm2-chat-1.8b	2.21B	304.01M / 12.60M / 约 1.8B
InternVL2-4B	InternViT-300M-448px	Phi-3-mini-128k-instruct	4.15B	304.01M / 22.03M / 3.82B
InternVL2-8B	InternViT-300M-448px	internlm2_5-7b-chat	8.08B	304.01M / 33.57M / 7.74B
InternVL2-26B	InternViT-6B-448px-V1.5	internlm2-chat-20b	25.51B	5.54B / 116.43M / 19.86B
InternVL2-40B	InternViT-6B-448px-V1.5	Nous-Hermes-2-Yi-34B	40.07B	5.54B / 143.17M / 34.39B
InternVL2-Llama3-76B	InternViT-6B-448px-V1.5	Hermes-2-Theta-Llama-3-70B	约 76B	博客模型卡未单列
InternVL2-108B	InternViT-6B-448px-V1.5	InternLM2-Chat-102B	108.70B	5.54B / 172.01M / 102.99B

表 1：InternVL 2.0 家族成员与底座对照（来源：官方博客模型卡 + InternVL 官方文档 introduction）

要点：视觉塔只有两档——小尺寸（1B/2B/4B/8B）用 InternViT-300M-448px，大尺寸（26B 及以上）用 InternViT-6B-448px-V1.5；语言底座则在 Qwen2、InternLM2/2.5、Phi-3、Yi、Llama-3 之间按尺寸选择，这是 Progressive Scaling Strategy 的直接体现。本地模型 InternVL2-1B 即家族最小尺寸：300M 视觉塔 + Qwen2-0.5B。

1.2 本地 InternVL2-1B config 实参表

下表逐字段来自本地 config 原文：E:\models\model\InternVL2-1B\config.json（legacy internvl_chat 格式，顶层含 llm_config 与 vision_config 两个嵌套块）。

字段（config.json）	取值	含义 / 备注
architectures	InternVLChatModel	legacy 入口类（官方仓库 modeling_internvl_chat.py）
model_type	internvl_chat	transformers 原生 internvl 格式为 2.5/3.x 才采用
auto_map	configuration / modeling_internvl_chat	trust_remote_code 加载
dynamic_image_size	true	动态分辨率切 tile 开关
force_image_size	448	每 tile 边长 448 像素
downsample_ratio	0.5	pixel shuffle 空间下采样比例
max_dynamic_patch	12	训练时最多 tile 数
min_dynamic_patch	1	最少 tile 数
ps_version	v2	pixel shuffle 版本
select_layer	-1	取视觉塔最后一层隐状态
use_thumbnail	true	额外拼一张 448×448 全局缩略图
template	Hermes-2	对话模板（ChatML 系）
torch_dtype	bfloat16	全局权重 dtype

表 2：本地 config 顶层实参（来源：E:\models\model\InternVL2-1B\config.json）

llm_config 字段	取值	含义
_name_or_path	Qwen/Qwen2-0.5B-Instruct	语言底座
architectures / model_type	Qwen2ForCausalLM / qwen2	Qwen2 解码器
hidden_size	896	残差流维度
num_hidden_layers	24	解码器层数
num_attention_heads	14	Q 头数
num_key_value_heads	2	KV 头数（GQA，分组数 7）
intermediate_size	4864	SwiGLN 单投影维度（hidden_act=silu）
vocab_size	151655	Qwen2 词表
max_position_embeddings	32768	位置编码上限
rope_theta	1000000.0	RoPE 基频
rms_norm_eps	1e-6	RMSNorm eps
sliding_window / use_sliding_window	32768 / false	配置存在但未启用（全注意力）
tie_word_embeddings	false	lm_head 独立

llm_config 字段	取值	含义
bos / eos_token_id	151643 / 151645	endoftext / im_end

表 3：本地 llm_config 实参（Qwen2-0.5B，来源：同 config.json）

vision_config 字段	取值	含义
architectures / model_type	InternVisionModel / intern_vit_6b	类型字符串沿用 6B 名，数值为 300M 规格
hidden_size	1024	视觉隐状态维度
num_hidden_layers	24	ViT 层数
num_attention_heads	16	视觉注意力头数
intermediate_size	4096	ViT MLP 中间维度（gelu）
patch_size / image_size	14 / 448	patch 14×14；tile 448×448
num_channels	3	RGB
qkv_bias / qk_normalization	true / false	QKV 带偏置；无 QK-Norm
layer_norm_eps / norm_type	1e-6 / layer_norm	Pre-LN ViT
use_flash_attn	true	视觉塔 FlashAttention

表 4：本地 vision_config 实参（来源：同 config.json；model_type 字符串与数值规格不一致处已并列标注）

1.3 token 数与投影维度复算

量	计算式	取值
每边 patch 数	448 / 14	32
每 tile patch token 数（含 CLS 前）	32 × 32 + 1	1025
每 tile 视觉 token（去 CLS、洗牌后）	$(32/2)^2$	256
洗牌后通道数	$1024 / 0.5^2$	4096
投影层形状	LN(4096)→Linear(4096→896)→gelu→Linear(896→896)	对齐 LLM hidden 896
单图最大视觉 token（训练）	(12 tile + 1 缩略图) × 256	3328

表 5：按 config 实参的 token 与维度复算（可复算）

2 端到端架构总览

一张 800×1300 的输入图像先按预定义宽高比匹配并切分为若干 448×448 tile，另加一张整图缩略图；每个 tile 各自过 InternViT 得到 1024 维特征图，经 pixel shuffle 空间减半、通道翻两番后由 MLP 投影层压到语言模型的 896 维；随后所有视觉特征按图

像顺序摊平，以 masked_scatter 方式写入输入序列中 <image> 占位符对应的位置，与文本 token 一同送入 Qwen2-0.5B 解码器。

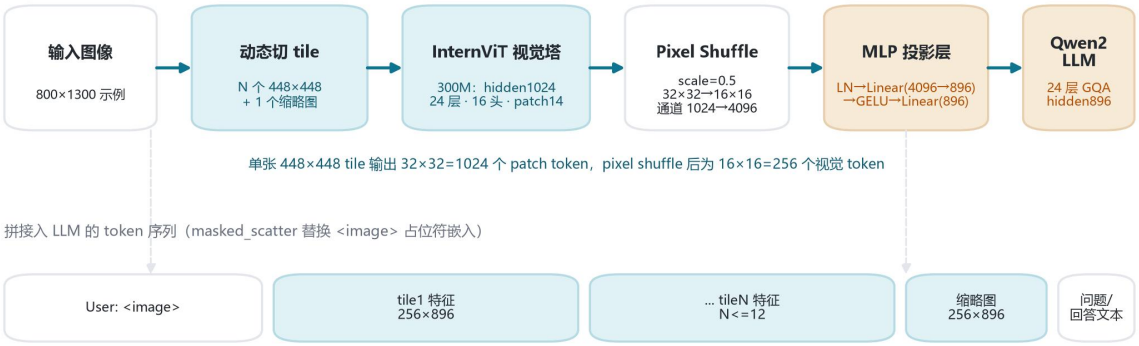


图 1：InternVL 2.0 端到端整体架构（以本地 1B 为主尺寸）

3 视觉编码器：InternViT 细节

家族视觉塔为两档规格。本地 1B 使用 InternViT-300M-448px：hidden 1024、24 层、16 头、head_dim 64、patch 14、tile 448×448、intermediate 4096、gelu、qkv_bias。大尺寸模型（26B+）使用 InternViT-6B-448px-V1.5（博客模型卡记 ViT 部分 5.54B 参数）。注意本地 config 的 vision_config.model_type 字符串仍写 intern_vit_6b，但全部数值字段都是 300M 规格——文中按规格事实区分两档，不被类型字符串误导。

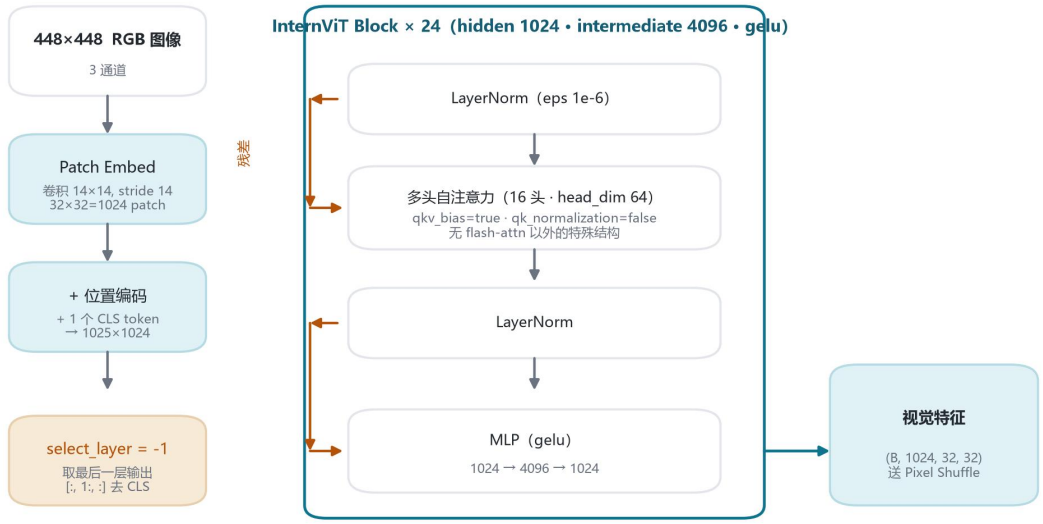


图 2：InternViT-300M 单层结构（本地 config 实参）

视觉特征取用：select_layer=-1 表示取 ViT 最后一层输出，随后丢弃 CLS token（[:, 1:, :]），把剩余 1024×32×32 特征图送 pixel shuffle。该路径与本地 transformers 源码 get_image_features（modeling_internvl.py:543-587）一致：vision_tower → 按层取特征 → 去 CLS → reshape 成二维特征图 → pixel_shuffle → multi_modal_projector。

4 投影层与语言底座

4.1 Pixel Shuffle（像素洗牌下采样）

pixel shuffle 把空间分辨率减半、通道数翻两番，在不丢信息的前提下把视觉 token 数压到四分之一。本地源码实现见 modeling_internvl.py:670-703，scale_factor 即 config 的 downsample_ratio=0.5。

符号	含义	本地取值
scale_factor	空间下采样比例	0.5（downsample_ratio）
C	ViT 输出通道	1024
H, W	tile 特征图边长	32, 32
洗牌后 H', W'	H×scale, W×scale	16, 16
洗牌后 C'	C / scale²	4096
每 tile token 数	H'×W'	256

表 6：pixel shuffle 符号表（源码 modeling_internvl.py:670-703）

4.2 MLP 投影层

投影层把 4096 维视觉特征对齐到语言模型的 896 维，结构为 LayerNorm → Linear → 激活 → Linear（源码 InternVLMultiModalProjector，modeling_internvl.py:485-500）：

y = Linear2(act(Linear1(LN(x))))，x: (N_tile, 256, 4096) → y: (N_tile, 256, 896)

4.3 语言底座 Qwen2-0.5B

本地 1B 的 LLM 是 Qwen2-0.5B-Instruct：hidden 896、24 层、14 个 Q 头配 2 个 KV 头（GQA，分组数 14/2=7）、intermediate 4864、silu 激活、RMSNorm（eps 1e-6）、RoPE（theta=1e6）、词表 151655、最大位置 32768。GQA 使 KV cache 体积为 MHA 的 1/7，是端侧 1B 模型的效率关键。家族更大尺寸依次换用 InternLM2-1.8B、Phi-3-mini、InternLM2.5-7B、InternLM2-20B、Yi-34B、Llama-3-70B 等底座（见表 1），投影层与视觉接口保持不变。

5 核心机制专节

5.1 动态分辨率 tile 与缩略图

动态高分辨率是 InternVL 1.5 引入、2.0 完整保留的机制：按输入图像宽高比在预定义比例集合（1:1、1:2、1:3、1:4、1:5、1:6、2:3、3:2 等）中找最接近者，把图缩放到该比例下若干个 448×448 tile 的组合，再额外拼一张整图缩小到 448×448 的缩略图，供模型感知全局语境。



图 3：动态分辨率 tile 机制（以 800×1300、命中 2:3 → 6 tile + 1 缩略图为例）

本地 config 实参：训练时最多 12 个 tile（max_dynamic_patch=12），官方口径测试可零样本放大到 40 个 tile（约 4K 分辨率）。上例 (6+1)×256 = 1792 个视觉 token。

5.2 token 流：视觉特征如何进入 LLM

前向时先把 input_ids 过词嵌入得到 (b, s, 896) 的文本嵌入；同时由 input_ids == image_token 构造布尔掩码，再把视觉支路输出的 (N_tile×256, 896) 特征用 masked_scatter 写进掩码为真的位置，最后送入 Qwen2 解码器。该实现对应源码 InternVLModel.forward（modeling_internvl.py:613-668）的 masked_scatter 段。

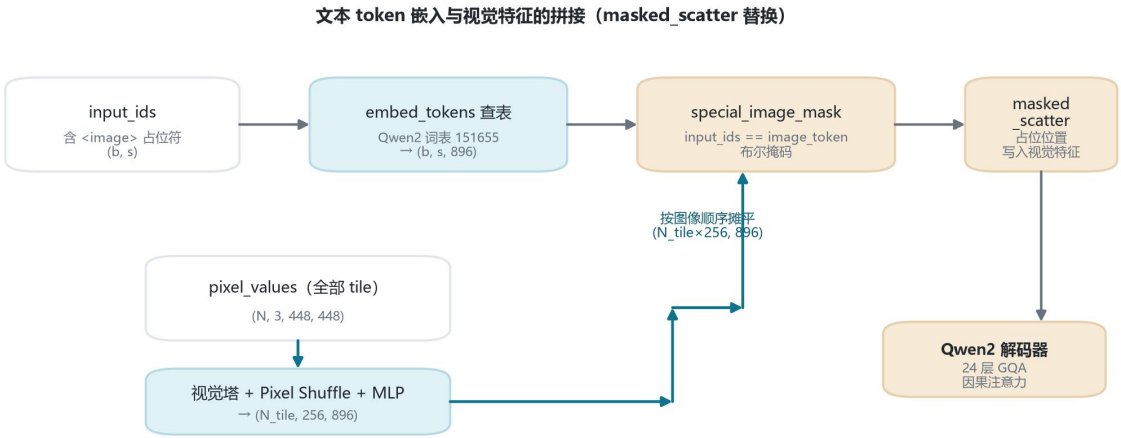


图 4：token 流（文本嵌入与视觉特征在 <image> 占位处拼接）

6 训练管线

InternVL 2.0 沿用两阶段训练，并以 Progressive Scaling Strategy 从 1B 到 108B 逐级扩展:

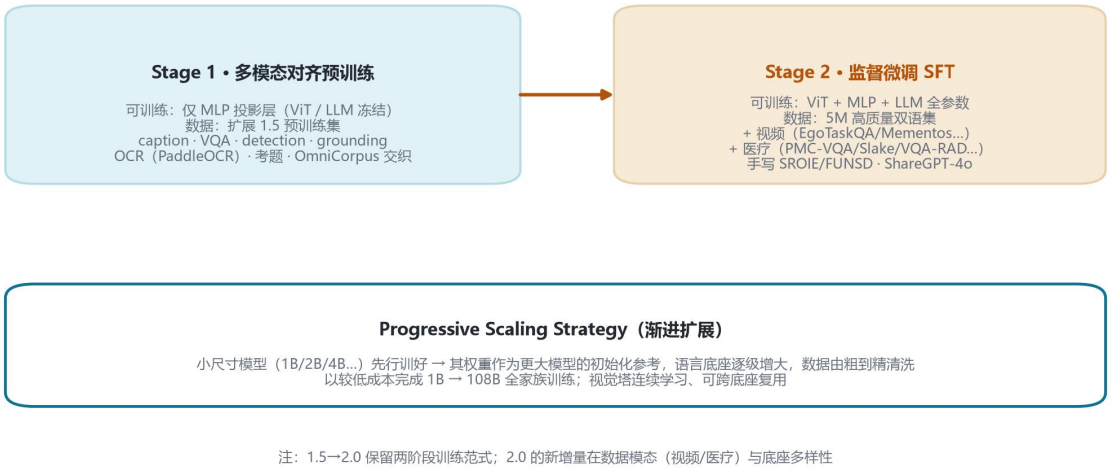


图 5：两阶段训练管线与渐进扩展策略

Stage 1（多模态对齐预训练）：只训练 MLP 投影层，视觉塔与 LLM 冻结；数据扩展自 InternVL 1.5 的预训练集，覆盖 caption、VQA、检测、grounding、OCR（PaddleOCR 标注中文 Wukong 与英文 LaionCOCO 图像）、考题（uworld/kaptest/testbank/aga/sat）与 OmniCorpus 交织数据。

Stage 2（监督微调 SFT）：放开视觉塔、MLP 与 LLM 全部参数；数据在 1.5 的 5M 高质量双语集基础上，新增视频（EgoTaskQA、Mementos、STAR、NTU RGB+D、VideoChat2IT、LSMDC-QA）、医疗数据（Medical-Diff-VQA、Pathology-VQA、PMC-CaseReport、PMC-VQA、Slake、VQA-RAD）、手写票据（SROIE、FUNSD、POIE），并用 ShareGPT-4o 替换原 ShareGPT-4V。家族以 8k 上下文训练，支持长文本、多图、视频与医疗输入。

7 版本演进对比：InternVL 1.5 → 2.0

InternVL 1.5（arXiv:2404.16821，2024-04）三大改进为：InternViT-6B 连续学习、动态高分辨率 tile、高质量双语数据集；2.0 在保留 ViT–MLP–LLM 母版与动态分辨率机制的前提下，把规模、底座与输入输出模态全面铺开。



图 6：InternVL 1.5 → 2.0 演进对比

维度	InternVL 1.5	InternVL 2.0
视觉塔	InternViT-6B-448px 单一规格	300M-448px（小模型）+ 6B-448px-V1.5（大模型），连续学习升级
语言底座	InternLM2-Chat-20B	扩展为 7 种底座（Qwen2-0.5B / InternLM2-1.8B / Phi-3-mini / InternLM2.5-7B / InternLM2-20B / Yi-34B / Llama-3-70B）
动态分辨率	1–40 tile × 448 + 缩略图	保留；训练 ≤12 tile、测试 ≤40 tile
输入模态	图 + 文本	图 + 视频 + 医疗 + 长文本 + 多图（8k 上下文）
输出能力	仅文本	VisionLLMv2 解码器：文本 + 框 + 掩码 + 图像
家族规模	约 1B / 2B / 26B	1B → 108B 全家族渐进扩展

表 7：1.5 → 2.0 关键差异对照

8 参考文献

[1] InternVL 2.0 官方博客：InternVL2: Better than the Best—Expanding Performance Boundaries of Open-Source Multimodal Models with the Progressive Scaling Strategy（2024-07-02）. https://internvl.github.io/blog/2024-07-02-InternVL-2.0/

[2] InternVL 1.5：How Far Are We to GPT-4V? Closing the Gap to Commercial Multimodal Models with Open-Source Suites. arXiv:2404.16821. https://arxiv.org/abs/2404.16821
[3] InternVL 1.0：InternVL: Scaling up Vision Foundation Models and Aligning for Generic Visual-Linguistic Tasks. arXiv:2312.14238. https://arxiv.org/abs/2312.14238
[4] VisionLLM v2: An End-to-End Generalist Multimodal Large Language Model for Hundreds of Vision-Language Tasks. arXiv:2406.08394. https://arxiv.org/abs/2406.08394
[5] InternVL 官方文档：Introduction of InternVL2 Series. https://internvl.readthedocs.io/en/latest/internvl2.0/introduction.html
[6] 本地 transformers 源码：E:\transformers\src\transformers\models\internvl\modeling_internvl.py（get_image_features:543-587；pixel_shuffle:670-703；InternVLMultiModalProjector:485-500；forward masked_scatter:613-668）
[7] 本地 config：E:\models\model\InternVL2-1B\config.json（internvl_chat 格式：llm_config=Qwen2-0.5B、vision_config=300M 规格、force_image_size=448、downsample_ratio=0.5、max_dynamic_patch=12、ps_version=v2、use_thumbnail=true、template=Hermes-2）

凡本地 config 与官方口径并列处（如 vision_config.model_type 字符串为 intern_vit_6b 而数值为 300M 规格；博客模型卡 2B 行 LLM 参数列与底座名口径），均按来源并列标注，未擅自统一。访问与核验日期：2026-10-26。