Moonshot-8B 家族架构详解

MoonshotAI/Moonshot-8B · 官方 repo 已于 2026-10-31 经 hf-mirror/ModelScope 核验为 404（已下架）· dense 待确认

依据：官方 config（hf-mirror / ModelScope 拉取，留档于 _tools_cfgpull\）+ transformers 源码（E:\transformers 可编辑安装）+ 官方论文 / model card。所有数值按 config 实际取值与官方说明逐项核对并标注来源；无法官方复核的数字统一标注「待确认」。

徽标：目标仓库 MoonshotAI/Moonshot-8B —— 2026-10-31 经 hf-mirror / ModelScope 核验为 404（不存在或已下架）

徽标：hf-mirror 组织列表共 19 个仓库，无 Moonshot-8B；全文搜索 / ModelScope / 社区镜像均无 config 留痕

徽标：Wayback Machine 在本网络不可达；论文候选号已勘误（见下）

徽标：以下任何架构数字均未经官方 config 复核，统一标「待确认」，不做编造

重要说明：本笔记对应任务书指定的 MoonshotAI/Moonshot-8B。经多通道核验，该仓库在 HuggingFace（hf-mirror 镜像）与 ModelScope 均返回 404；moonshotai 组织当前公开的 19 个仓库中没有该模型。因此无法取得官方 config.json，本页只记录核验过程、可旁证的背景，以及「待确认」清单，不臆造任何层数 / hidden / 词表 / RoPE 数值。

1 家族全景：核验记录与「待确认」config 表

下表字段全部标注「待确认」。任务书最初提示「dense、全注意力、长上下文（128K？）、层数、hidden、词表、RoPE base、MLA 与否」，但这些均未获得官方 config 或 model card 复核。

字段	任务书提示	本笔记结论	来源状态
形态	dense	待确认	无 config / card 复核
注意力	全注意力	待确认（是否 MLA 未知）	无 config 复核
上下文	128K?	待确认	无 card 复核
num_hidden_layers	—	待确认	无 config
hidden_size	—	待确认	无 config
num_attention_heads / KV	—	待确认	无 config

字段	任务书提示	本笔记结论	来源状态
intermediate_size	—	待确认	无 config
vocab_size	—	待确认	无 config
max_position_embeddings	—	待确认	无 config
rope_theta	—	待确认	无 config
MoE / 专家配置	应为 dense（无 MoE）	待确认	无 config

1.1 已执行的核验通道与结果

通道	查询	结果
hf-mirror 仓库直连	moonshotai/Moonshot-8B/resolve/main/config.json	404
hf-mirror 变体	-Base / -Instruct 后缀	均 404
ModelScope	moonshotai/Moonshot-8B repo API	404
hf-mirror 组织列表	api/models?author=moonshotai	19 个仓库，无 Moonshot-8B
hf-mirror 全文搜索	search=Moonshot-8B / Moonshot 8B	0 命中
Wayback Machine	web.archive.org 快照	本网络不可达（连接超时）

2 端到端数据流总览（通用骨架，非该模型实测）

在无 config 的前提下，下图只画一个「dense Transformer」通用骨架（Embedding → N×DecoderLayer → RMSNorm → LM Head），用于占位；图中所有超参均为待确认。

2.1 架构图

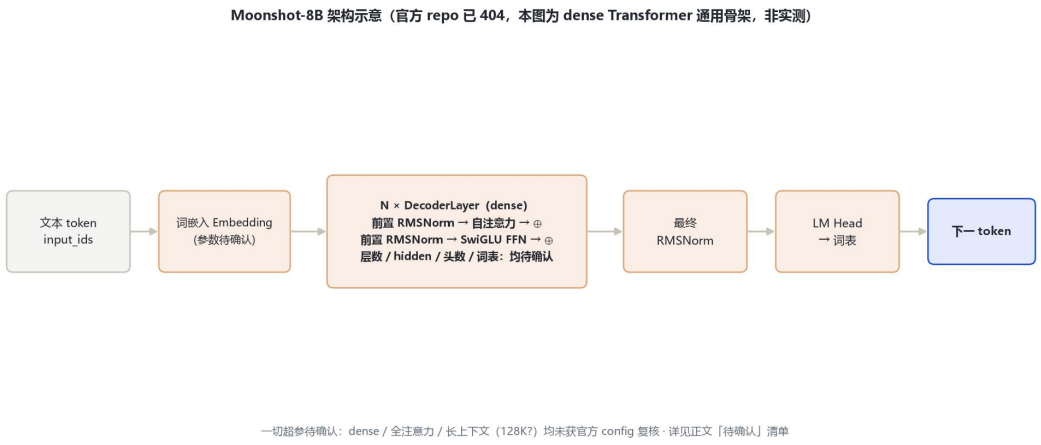


图 1：架构图：Moonshot-8B 通用 dense 骨架示意（非实测）

3 解码层与核心机制（待确认）

因无官方实现代码或 config，无法给出该模型真实的归一化、激活、MoE 路由细节。参考同系列同期真实开源模型 Moonlight-16B-A3B（见 §6）的 DeepSeek-V3 式 MLA-MoE 结构，不能直接套用到 Moonshot-8B。

4 注意力机制（待确认）

任务书提示「全注意力」，但「是否 MLA、Q/KV 头数、head_dim」均无官方字段佐证。统一标待确认。

5 特殊 Token 与词表（待确认）

vocab_size、bos/eos/pad id 均无官方字段。统一标待确认。

6 演进视角：Moonshot 早期真实开源模型对照

moonshotai 组织在 2025 年初真实开源的文本/稀疏模型是 Moonlight-16B-A3B（2025-02/03，Muon 优化器首次大规模训练实践配套发布），并非名为「Moonshot-8B」的 dense 模型。其官方 config 实测值（留档 _tools_cfgpull\Moonlight-16B-A3B.config.json）：

字段	Moonlight-16B-A3B（真实存在）
model_type / architectures	deepseek_v3 / DeepseekV3ForCausalLM
hidden_size	2048
num_hidden_layers	27
num_attention_heads / KV	16 / 16
intermediate_size（dense）	11264
moe_intermediate_size	1408
n_routed_experts / n_shared_experts / top	64 / 2 / 6
MLA	kv_lora_rank 512 · q_lora_rank 无 · qk_nope 128 · qk_rope 64 · v_head 128
vocab_size / max_position / rope_theta	163840 / 8192 / 50000

说明：若任务书的「Moonshot-8B」实为对早期开源模型的误记，最接近的真实对象是 Moonlight-16B-A3B（16B 总 / 3B 激活 MoE，非 8B dense）。本页不做替换，仅作对照。系列内其他官方模型（Kimi-K2 系列、Kimi-Linear、Kimi-VL、Kimi-Audio、MoonViT 等）见 Kimi-K2-0905 笔记演进章。

7 来源

1. hf-mirror 组织仓库列表（2026-10-31 核验，19 个仓库无 Moonshot-8B）

https://hf-mirror.com/api/models?author=moonshotai

2. hf-mirror / ModelScope 仓库直连（均 404）

https://hf-mirror.com/moonshotai/Moonshot-8B/resolve/main/config.json ；https://modelscope.cn/api/v1/models/moonshotai/Moonshot-8B

3. Moonlight-16B-A3B 官方 config（真实早期开源模型对照）

E:\transformers\bayon-note\Kimi\moonshot_32b_a32b_tools_cfgpull\Moonlight-16B-A3B.config.json

4. Moonshot 官方技术博客：Muon 优化器首次大规模训练实践（Moonlight 模型）

https://platform.moonshot.cn/blog/posts/moonlight

5. Kimi k1.5 技术报告（arXiv:2501.12599，未开放权重）

https://arxiv.org/abs/2501.12599

勘误：任务书最初给出的候选论文号 arXiv:2501.08504 经核实为《SuperSAM: Crafting a SAM Supernetwork…》（医学图像分割），与 Moonshot 无关，不予引用。访问与核验日期：2026-10-31。

页脚：Moonshot-8B 架构详解（官方 repo 已 404）· 数据来源：hf-mirror/ModelScope 核验记录 + Moonlight 官方 config 对照 · 未复核数字一律标待确认 · 仅供技术学习与论文研究