Kimi-K2-0905 家族架构详解

DeepseekV3ForCausalLM / model_type=kimi_k2 · 1T-A32B · MLA · 384 路由专家+1 共享 · top-8 · 262144 上下文

依据：官方 config（hf-mirror / ModelScope 拉取，留档于 _tools_cfgpull\）+ transformers 源码（E:\transformers 可编辑安装）+ 官方论文 / model card。所有数值按 config 实际取值与官方说明逐项核对并标注来源；无法官方复核的数字统一标注「待确认」。

徽标：入口类 DeepseekV3ForCausalLM（config.architectures）· model_type = kimi_k2 · auto_map 指向官方仓库 configuration_deepseek / modeling_deepseek

徽标：复用 DeepSeek-V3 实现代码——本地 transformers 无原生 kimi_k2 模块，按官方 repo 远端代码加载（本地 models\deepseek_v3 为同架构等价实现）

徽标：MLA 低秩联合压缩（kv_lora_rank 512 · q_lora_rank 1536 · qk_nope 128 · qk_rope 64 · v_head 128）

徽标：384 路由专家 + 1 共享专家 · 每 token top-8 · sigmoid 打分 · routed_scaling_factor 2.827

徽标：hidden 7168 · 61 层（第 0 层 dense，1–60 层 MoE）· 词表 163840 · 上下文 262144（YaRN）

本页以 Kimi-K2-Instruct-0905 官方 config.json（2026-10-31 经 hf-mirror 拉取，留档 _tools_cfgpull\config.json）与 transformers 源码（本地 E:\transformers，models\deepseek_v3\ 同架构等价实现）为唯一依据。K2 系列技术事实以官方论文 arXiv:2507.20534《Kimi K2: Open Agentic Intelligence》为准。所有数字均标注来源（config 字段或源码文件:行号）。

1 家族全景：K2-0905 config 实参对照

下表字段全部来自官方 config（逐字段核对，2026-10-31）。0905 与 Kimi-K2-Base / Kimi-K2-Instruct 共享同一文本塔架构，主要差异在上下文长度与权重量化格式。

字段（config）	Kimi-K2-0905 取值	来源
architectures	DeepseekV3ForCausalLM	config.architectures
model_type	kimi_k2	config.model_type

字段（config）	Kimi-K2-0905 取值	来源
auto_map	AutoConfig→configuration_deepseek / AutoModelForCausalLM→modeling_deepseek（官方 repo 远端代码）	config.auto_map
形态	MoE（第 0 层 dense，其余 60 层 MoE）	first_k_dense_replace=1
hidden_size	7168	config
num_hidden_layers	61	config
num_attention_heads (Q)	64	config
num_key_value_heads (KV)	64	config（MLA 下为压缩后低秩，非 GQA）
intermediate_size（dense FFN，第 0 层）	18432	config
moe_intermediate_size	2048	config
first_k_dense_replace	1（仅第 0 层 dense）	config
moe_layer_freq	1（之后每层都走 MoE）	config
n_routed_experts（路由专家）	384	config
n_shared_experts（共享专家）	1	config
num_experts_per_tok	8	config
kv_lora_rank（KV 低秩压缩维）	512	config
q_lora_rank（Q 低秩压缩维）	1536	config
qk_nope_head_dim	128（无位置编码部分）	config
qk_rope_head_dim	64（RoPE 部分）	config
v_head_dim	128	config
vocab_size	163840	config
max_position_embeddings	262144	config
rope_theta	50000.0	config
rope_scaling	yarn，factor 64.0，original_max_position_embeddings 4096，beta_fast/slow 1.0，mscale 1.0	config
attention_bias / attention_dropout	false / 0.0	config
hidden_act	silu	config
rms_norm_eps	1e-5	config
tie_word_embeddings	false	config
scoring_func / topk_method	sigmoid / noaux_tc	config
routed_scaling_factor	2.827	config
norm_topk_prob	true	config
aux_loss_alpha	0.001	config
bos / eos / pad token id	163584 / 163585 / 163839	config
quantization_config	fp8，fmt e4m3，weight_block_size [128,128]，activation_scheme dynamic	config

要点：① 入口类是 DeepseekV3ForCausalLM 而非某个 kimi 专属类——K2-0905 直接复用 DeepSeek-V3 的模型结构与远端实现代码，model_type 虽为 kimi_k2，但 config.architectures 与 auto_map 均指向 deepseek 实现；② 注意力是 MLA（Multi-head

Latent Attention）而非普通 GQA：Q/KV 先各自低秩压缩（q_lora_rank 1536、kv_lora_rank 512），再拆分出「无位置」与「RoPE」两段；③ MoE 为 384 路由专家 + 1 共享专家，每 token 选 8，第 0 层是 dense FFN；④ 官方论文口径：总参数约 1.04T、每 token 激活约 32B（即「1T-A32B」）。

1.1 与 Kimi-K2-Base / Instruct 的差异

字段	Kimi-K2-Base	Kimi-K2-0905	说明
hidden_size	7168	7168	相同
num_hidden_layers	61	61	相同
专家配置	384 路由 + 1 共享 / top-8	同左	相同
MLA 维度	kv 512 · q 1536 · nope 128 · rope 64 · v 128	同左	相同
max_position_embeddings	131072	262144	0905 翻倍扩长
rope_scaling	无显式	yarn factor 64（original 4096）	0905 用 YaRN 扩到 256K
quantization_config	无（bf16 裸权重）	fp8 e4m3（block 128）	0905 附带 fp8 官方权重
vocab_size	163840	163840	相同

对照来源：moonshotai/Kimi-K2-Base config（留档 kimi_k2_0905_tools_cfgpull\Kimi-K2-Base.config.json）。0905 是 2025-09 放出的更新版 Instruct 检查点，文本塔与 Base 同架构，主要工程变化是上下文翻倍到 262144 并以 fp8 e4m3 格式发布。

2 端到端数据流总览

文本 token → 词嵌入（untied）→ 第 0 层 dense 解码层（MLA 注意力 + 18432 维 SwiGLU FFN）→ 层 1–60 MoE 解码层（MLA 注意力 + 384 路由专家选 8 / 1 共享专家）→ 最终 RMSNorm → LM Head（7168→163840，untied）。

2.1 架构图

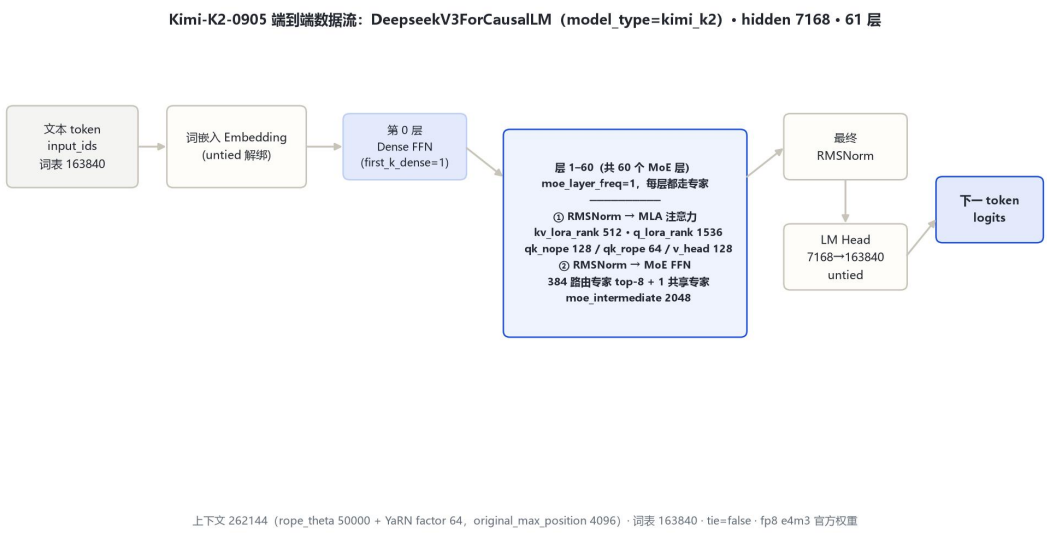


图 1：架构图：Kimi-K2-0905 端到端数据流总览

全模型统一主干：Embedding → 61 层解码块（第 0 层 dense，后 60 层 MoE）→ RMSNorm → LM Head；差异集中在 FFN 子层：第 0 层是 dense SwiGLU，其余 60 层是 top-8 细粒度 MoE。

3 解码层解剖：DeepSeek-V3 式前置 RMSNorm 残差块

K2-0905 的解码层与 DeepSeek-V3 同构（本地等价实现 DeepseekV3DecoderLayer，models\deepseek_v3\modeling_deepseek_v3.py:485）：每组含注意力与 FFN 两个残差子层，均为单 RMSNorm 前置。第 0 层 FFN 是 dense SwiGLU（18432 维），其余层 FFN 是 MoE。

```
DecoderLayer.forward（DeepSeek-V3 式，等价实现 modeling_deepseek_v3.py:485
起）：
  residual = hidden_states
  hidden_states = input_layernorm(hidden_states)        # RMSNorm(7168,
eps 1e-5)
  hidden_states, _ = self_attn(hidden_states)          # MLA：低秩压缩 +
RoPE
  hidden_states = residual + hidden_states            # ⊕1
  residual = hidden_states
  hidden_states = post_attention_layernorm(hidden_states)
  # 第 0 层：dense MLP(18432)；其余层：MoE(384 路由选 8 + 1 共享，moe_inter
2048)
  hidden_states = self.mlp(hidden_states)
  hidden_states = residual + hidden_states            # ⊕2
```

```
    return hidden_states
```

3.1 架构图

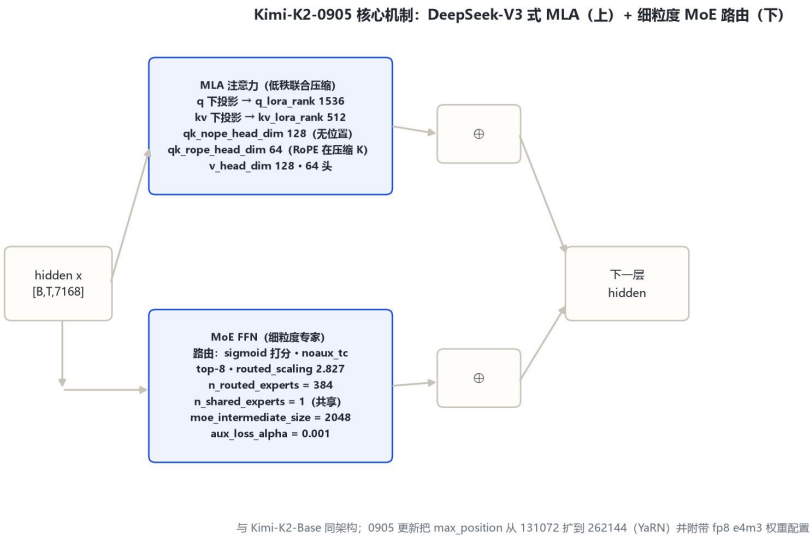


图 2：架构图：Kimi-K2-0905 核心机制（MLA + MoE 路由）

4 核心机制：MLA 低秩压缩 · 384 专家路由 · YaRN 扩长

4.1 ① MLA：Q/KV 低秩联合压缩

注意力不再直接投影出全部 Q/KV 头，而是先把 hidden 压到低秩隐向量，再上投影回多头（等价实现 DeepseekV3Attention，modeling_deepseek_v3.py:349-394）：

$$q = W^{(qB)}\, x \in \mathbb{R}^{(q_lora_rank=1536)},\ c^{(KV)} = W^{(KV)}\, x \in \mathbb{R}^{(kv_lora_rank=512)}$$

$$c^{(KV)} \rightarrow \mathrm{RMSNorm}(c^{(KV)});\ \mathrm{split}(c^{(KV)}, kv_lora_rank, qk_rope_head_dim=64)$$

$$q' = \mathrm{RMSNorm}(q)\, W^{(qA)};\ k = k_nope + k_rope;\ v = v_nope$$

关键：KV cache 只缓存低秩的 512 维隐向量（而非 64 头 × 128 维），大幅压缩 KV 占用；RoPE 只作用在拆分出的 64 维 qk_rope_head_dim 段，其余 128 维 qk_nope_head_dim 不带位置编码（modeling_deepseek_v3.py:389,445）。

4.2 ② MoE 路由：384 路由专家选 8 + 1 共享专家

MoE 块（等价实现 DeepseekV3MoE，modeling_deepseek_v3.py:201；专家 MLP :104-157）：

```
router_logits = x @ W_gate^T                        # (seq, 384)
scores = sigmoid(router_logits)                     # scoring_func=sigmoid
（非 softmax）
topk_weights, topk_idx = noaux_tc_topk(scores, k=8)   #
topk_method=noaux_tc
topk_weights = topk_weights * routed_scaling_factor(2.827)  # :157
topk_weights = topk_weights / topk_weights.sum(-1)            #
norm_topk_prob=true
# 384 个路由专家按 topk_idx 分桶计算（moe_intermediate=2048）
# 另有 1 个共享专家（n_shared_experts=1）对所有 token 始终计算
```

配置口径：n_routed_experts=384、n_shared_experts=1、num_experts_per_tok=8、moe_intermediate_size=2048、routed_scaling_factor=2.827、aux_loss_alpha=0.001、seq_aux=true。官方论文（arXiv:2507.20534）说明：在固定激活参数量下扩大路由专家总数（稀疏度 384/8=48）可降低 loss，故采用 384 路由专家。

4.3 ③ YaRN 扩长到 262144

```
rope_theta = 50000
rope_scaling = { type: "yarn", factor: 64.0,
                 original_max_position_embeddings: 4096,
                 beta_fast: 1.0, beta_slow: 1.0, mscale: 1.0 }
max_position_embeddings = 262144
```

Kimi-K2-Base 原生 max 为 131072；0905 通过 YaRN（factor 64，基准 4096）把有效上下文扩到 262144。RoPE 基频 rope_theta=50000。

5 注意力机制：MLA（非 GQA）· 64 头 · 无注意力偏置

5.1 头与低秩维度

维度	取值	含义
num_attention_heads (Q)	64	Q 头数
num_key_value_heads	64	名义 KV 头（MLA 下共享低秩 KV 隐向量）
q_lora_rank	1536	Q 低秩压缩维
kv_lora_rank	512	KV 低秩压缩维（KV cache 实际缓存量）
qk_nope_head_dim	128	每头 QK 无位置段维度

维度	取值	含义
qk_rope_head_dim	64	每头 QK RoPE 段维度
v_head_dim	128	每头 value 维度
attention_bias	false	Q/K/V/O 投影均无偏置

5.2 注意力核心

$$\text{Attn}(Q,K,V)=\text{softmax}((QK^{\wedge T})/(\sqrt{(d_hk)})+\text{mask})V$$

```
# MLA 下 Q 经 q_a_layernorm 后上投影为 64 头；
# KV 隐向量 512 维与 rope 段 64 维拼接后再扩为多头；
# 因果掩码，无滑窗（全注意力）。
```

与普通 GQA 的区别：GQA 是 Q 多头、KV 分组共享；MLA 是 Q/KV 都先压到低秩瓶颈再解多头，KV cache 体积由 kv_lora_rank=512 决定，而非头数×head_dim。

6 特殊 Token 与词表布局

token	ID	含义	来源
bos_token_id	163584	序列开始	config
eos_token_id	163585	序列结束	config
pad_token_id	163839	填充	config
vocab_size	163840	词表大小（2^17 对齐）	config

词表 vocab_size=163840。tokenizer_class 字段为 null（随官方 repo 代码提供）。无多模态特殊 token——K2-0905 为纯文本稠密/稀疏文本模型（视觉能力由 Kimi-VL 系列承担，本笔记不展开）。

7 演进视角：Moonlight → Kimi-K2-Base → Kimi-K2-0905

维度	Moonlight-16B-A3B（2025-02，早期开源）	Kimi-K2-Base（2025-07）	Kimi-K2-0905（2025-09）
形态	MoE 16B 总 / 3B 激活	MoE 1T 总 / 32B 激活	同 K2-Base
hidden / 层数	2048 / 27	7168 / 61	7168 / 61
注意力	MLA（kv 512，无 q_lora_rank）	MLA（kv 512 · q 1536）	MLA（同 Base）
路由专家	64 路由 + 2 共享，top-6	384 路由 + 1 共享，top-8	384 路由 + 1 共享，top-8
max_position	8192	131072	262144（YaRN）
rope_theta	50000	50000	50000 + yarn factor64
权重格式	bf16	bf16	fp8 e4m3
vocab	163840	163840	163840

演进主线：① 文本塔从 Moonlight 的 2048/27 层扩到 K2 的 7168/61 层；② MLA 引入 q 侧低秩压缩（q_lora_rank 1536），KV 低秩维保持 512；③ 路由专家从 64（top-6，2 共享）扩到 384（top-8，1 共享），稀疏度大幅提升；④ 上下文 8192 → 131072 → 262144（YaRN）；⑤ 0905 附带 fp8 e4m3 官方权重。Moonlight 数据来自 moonshotai/Moonlight-16B-A3B 官方 config（留档 moonshot_32b_a32b_tools_cfgpull\）。

系列内其他官方模型（本次未单独立目录）：Kimi-K2-Instruct、Kimi-K2-Thinking（K2 的 thinking 变体）、Kimi-K2.5 / K2.6 / K2.7-Code（后续代际）、Kimi-K3（2026-07，2.8T，KDA 混合线性注意力）、Kimi-Linear-48B-A3B（线性注意力）、Kimi-VL-A3B 系列（视觉）、Kimi-Audio-7B（语音）、MoonViT-SO-400M（视觉编码器）。

8 来源

1. Kimi-K2-Instruct-0905 官方 config（2026-10-31 经 hf-mirror 拉取，逐字段核对）

E:\transformers\bayon-note\Kimi\kimi_k2_0905_tools_cfgpull\config.json（architectures=DeepseekV3ForCausalLM / model_type=kimi_k2 / hidden 7168 / 61 层 / 64Q·64KV / inter 18432 / moe_inter 2048 / 384 路由+1 共享 / top-8 / kv_lora 512 / q_lora 1536 / nope128·rope64·v128 / vocab 163840 / max 262144 / rope θ50000+yarn64 / tie=false / fp8 e4m3）

2. Kimi-K2-Base 官方 config（对照 0905 差异）

E:\transformers\bayon-note\Kimi\kimi_k2_0905_tools_cfgpull\Kimi-K2-Base.config.json（同架构，max 131072，无 rope_scaling，无 fp8 quant_config）

3. transformers 源码（本地 E:\transformers，同架构等价实现）

models\deepseek_v3\modeling_deepseek_v3.py：MLP 104-157（routed_scaling 127,157）；MoE 201；Attention 349-394（q/kv lora 360-392）；compressed_kv split 445；DecoderLayer 485

4. Kimi K2 技术报告（arXiv:2507.20534）

https://arxiv.org/abs/2507.20534 （Kimi K2: Open Agentic Intelligence； 1.04T 总参 / 32B 激活；384 专家稀疏度 48；MuonClip 优化器；15.5T tokens）

5. Kimi K2 官方 HF 仓库

https://huggingface.co/moonshotai/Kimi-K2-Instruct-0905 （hf-mirror 镜像： https://hf-mirror.com/moonshotai/Kimi-K2-Instruct-0905）

6. moonshotai HF 组织仓库列表（2026-10-31 核验）

https://hf-mirror.com/api/models?author=moonshotai （共 19 个仓库； K2-0905 复用 deepseek 实现代码）

标注约定：config 字段名即来源；[S:n]=本地等价实现 modeling_deepseek_v3.py 行号。K2-0905 官方 repo 以 auto_map 指向其自带 modeling_deepseek.py，本地 transformers v5 无原生 kimi_k2 模块，故以「官方 config + 本地 deepseek_v3 同架构等价实现 + arXiv 论文」三来源交叉核对。访问与核验日期：2026-10-31。

页脚： Kimi-K2-0905 架构详解 · 数据来源： 官方 config （hf-mirror） + transformers 源码 （E:\transformers） + arXiv:2507.20534 · 仅供技术学习与论文研究