Qwen 3 家族架构详解

Qwen3ForCausalLM / Qwen3MoeForCausalLM / Qwen3VLForConditionalGeneration · Dense 0.6B-32B + MoE 30B-A3B/235B-A22B + 3-VL

依据：本机 ModelScope 下载的 config.json + transformers 源码 （E:\transformers 可编辑安装）+ 官方技术报告。所有数值按 config 实际取值与源码 forward 路径逐项复算并标注来源。

徽标：入口类 Qwen3ForCausalLM （Dense） / Qwen3MoeForCausalLM （MoE） / Qwen3VLForConditionalGeneration（3-VL）

徽标：原生 thinking 模式（/think /no_think 软切换、enable_thinking 硬开关、思维块用 <think>...</think> 编码进序列）

徽标：全注意力（无滑窗，sliding_window=null）· head_dim 128 · 逐头 Q/K RMSNorm（QK-Norm）· attention_bias=false

徽标：GQA 全系（8B 起 tie=False）· 词表 151936 · rope_theta 1e6（文本）· 基座 max_position 40960（3-VL 文本 262144）

徽标（青/多模态）：3-VL 视觉塔 patch 16 · spatial_merge 2 · text rope_theta 5e6（M-RoPE）；另有 3-ASR （qwen3_asr）、3-Omni-MoE （qwen3_omni_moe）、MTP（qwen3_next）

本页以 各变体真实 config.json（本地 Qwen3-0.6B、Qwen3-VL-2B-Instruct，以及经 hf-mirror 拉取的 1.7B / 4B / 8B / 14B / 32B / 30B-A3B / 235B-A22B 官方 config）与 transformers 源码 （本地 E:\transformers， models\qwen3\ 、 models\qwen3_moe\ 、 models\qwen3_vl\、models\qwen3_next\）为唯一依据。所有数字均标注来源（config 字段或源码文件:行号）。

1 家族全景：文本塔核心超参数对照

下表 Dense 六档 + MoE 两档的文本塔字段，全部来自官方 config（2026-10-26 经 hf-mirror 逐字段核对；0.6B 为本地 E:\models\qwen\Qwen3-0.6B\config.json）。八档共用同一主干：RMSNorm 前置残差块、SwiGLU FFN、GQA、head_dim 128、逐头 Q/K RMSNorm、无注意力偏置。

字段	0.6B	1.7B	4B	8B	14B	32B	30B-A3B	235B-A22B
入口类	Qwen3ForCausalLM	同左	同左	同左	同左	同左	Qwen3MoeForCausalLM	Qwen3MoeForCausalLM
model_type	qwen3	qwen3	qwen3	qwen3	qwen3	qwen3	qwen3_moe	qwen3_moe
形态	Dense	Dense	Dense	Dense	Dense	Dense	MoE	MoE
hidden_size	1024	2048	2560	4096	5120	5120	2048	4096
num_hidden_layers	28	28	36	36	40	64	48	94
num_attention_heads (Q)	16	16	32	32	40	64	32	64
num_key_value_heads (KV)	8	8	8	8	8	8	4	4
head_dim	128	128	128	128	128	128	128	128
intermediate_size（Dense FFN）	3072	6144	9728	12288	17408	25600	6144	12288
num_experts / 每 token 激活	—	—	—	—	—	—	128 / 8	128 / 8
moe_intermediate_size	—	—	—	—	—	—	768	1536
tie_word_embeddings	true	true	true	false	false	false	false	false
vocab_size	151936	151936	151936	151936	151936	151936	151936	151936
max_position_embeddings	40960	40960	40960	40960	40960	40960	40960	40960
rope_theta	1e6	1e6	1e6	1e6	1e6	1e6	1e6	1e6
sliding_window	null	null	null	null	null	null	null	null

要点：① 八档全部 sliding_window=null、use_sliding_window=false——Qwen3 注意力从 Qwen2/Qwen2.5 的滑窗回到全注意力（源码里 sliding_window 仅当 layer_type==“sliding_attention” 才非空，qwen3 config 不设该字段，modeling_qwen3.py:231）；② head_dim 统一 128，故 Q 投影输出维 = Q 头数 × 128（如 32B：64×128=8192=hidden）；③ MoE 两档 decoder_sparse_step=1（每一层都是专家层），num_experts=128、每 token 选 8 个；config 中无 shared_expert_intermediate_size 字段——Qwen3 MoE 为纯 top-k 路由专家（这一点与 Qwen3.5 MoE 的显式共享专家不同，见演进章）；④ 小尺寸（≤4B）tie 共享嵌入，8B 起解绑。

1.1 变体与部署规格

变体	入口类 / model_type	文本塔锚点	视觉塔	上下文	说明
Qwen3-0.6B（本地）	Qwen3ForCausalLM / qwen3	hidden 1024 · 28 层 · 16Q·8KV · inter 3072	无	40960	本地 config 逐字段核对
3-VL-2B（本地）	Qwen3VLForConditionalGeneration / qwen3_vl	hidden 2048 · 28 层 · 16Q·8KV · head_dim 128 · inter 6144 · rope_theta 5e6	hidden 1024 · depth 24 · patch 16 · temporal 2 · spatial_merge 2	262144	本地 config 逐字段核对
3-VL-4B / 8B / 32B	同左	沿用对应 Dense 文本塔	同一支视觉塔配置	262144	官方 model card（尺寸 exact 见 card，待确认项见 §9）
3-VL-30B-A3B	Qwen3VLMoeForConditionalGeneration / qwen3_vl_moe	30B-A3B 文本塔 + 视觉塔	同上	262144	MoE 视觉版
3-ASR	qwen3_asr	语音识别专用	音频编码器	—	源码 models\qwen3_asr\
3-Omni	Qwen3OmniMoeForConditionalGeneration / qwen3_omni_moe	全模态（文/图/音）	视觉+音频双塔	—	源码 models\qwen3_omni_moe\
MTP	qwen3_next	投机解码头（Multi-Token Prediction）	—	—	源码 models\qwen3_next\，训练时多步预测

2 端到端数据流总览

文本 token → 词嵌入（小尺寸与 hidden 绑定）→ N 个 Qwen3DecoderLayer（前置 RMSNorm：注意力子层 + SwiGLU FFN 子层，均带残差）→ 最终 RMSNorm → LM Head（8B 起不绑定嵌入）。3-VL 多一路：图像/视频 patch 经视觉塔编码、spatial_merge 压缩、投影到文本 hidden 后，按 image/video 特殊 token 位 early-fusion 进同一序列。MoE 档把 FFN 子层换成 top-k 路由的 128 专家。

2.1 架构图

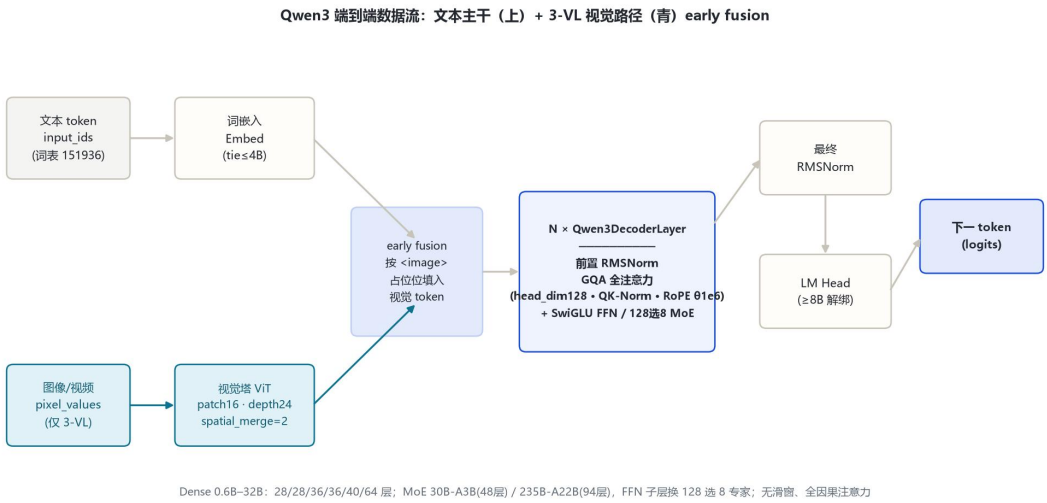


图 1：架构图：Qwen3 家族端到端数据流总览

全家族统一主干：Embedding → N×DecoderLayer（GQA 全注意力 + SwiGLU/MoE-FFN）→ RMSNorm → LM Head；差异集中在层数、维度、MoE 路由，以及 3-VL 是否挂视觉塔。

3 解码层解剖：Qwen3 前置 RMSNorm 残差块

Qwen3DecoderLayer（modeling_qwen3.py:275-315）含两组残差子层：注意力子层与 FFN 子层，均为单 RMSNorm 前置（无 post-norm，区别于 Gemma 3 的双 RMSNorm）。Dense 与 MoE 仅 FFN 子层不同。

3.1 架构图

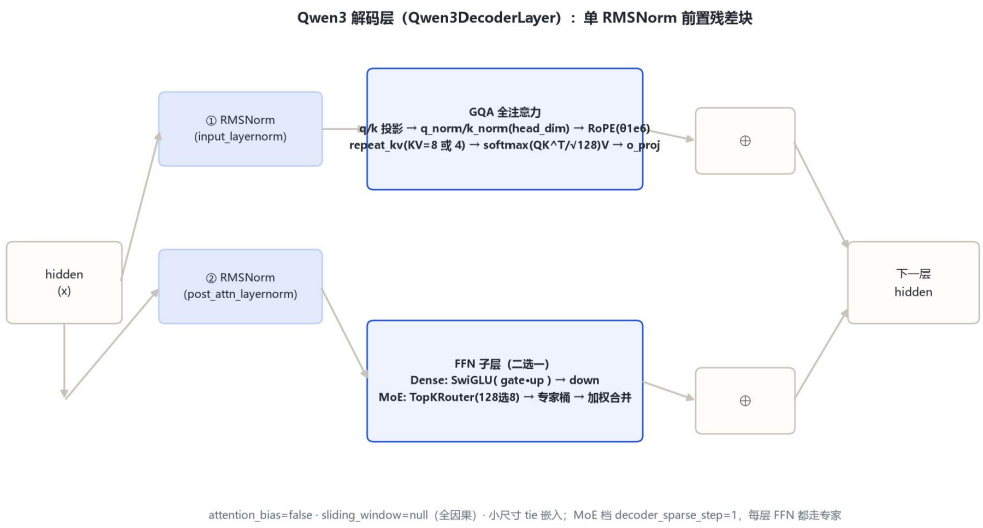


图 2：架构图：Qwen3 解码层解剖（含 QK-Norm 与 MoE 路由分支）

```
Qwen3DecoderLayer.forward（modeling_qwen3.py:286-315）：
  residual = hidden_states
  hidden_states = input_layernorm(hidden_states)          # RMSNorm(hidden)
  hidden_states, _ = self_attn(hidden_states, ...)        # GQA + QK-Norm
+ RoPE
  hidden_states = residual + hidden_states                # ⊕1
  residual = hidden_states
  hidden_states = post_attention_layernorm(hidden_states)
  hidden_states = self.mlp(hidden_states)               # SwiGLU（Dense）/
128 选 8 专家（MoE）
  hidden_states = residual + hidden_states                # ⊕2
  return hidden_states
```

4 核心机制：thinking · QK-Norm · GQA · MoE 路由

4.1 ① 原生 thinking 模式与软切换

Qwen3 是首个把「先思维、后作答」作为默认行为的 Qwen 代际。思维块直接以文本标记 <think>...</think> 编码进输出序列，推理产物与回答在同一流里。两层控制：

硬开关：生成时 enable_thinking=True/False（默认 True）；关则直接作答（官方 quickstart）。

软切换：在 user/system 消息里加 /think 或 /no_think，多轮对话跟随最近一条指令（官方文档原文：The model will follow the most recent instruction）。

```
用户：把这堆数排个序 /think
模型：<think> 先确认输入…再选升序… </think>
      好的，结果是 …
用户：换个方式，别说过程 /no_think
模型：<think>（本轮不输出思维）</think>  结果是 …
```

注意：Qwen3.5 起取消 /think 软切换、thinking 默认常开（见 §8）。

4.2 ② 逐头 Q/K RMSNorm（QK-Norm）

Qwen3Attention 在 Q/K 投影后、RoPE 前各过一个维度等于 head_dim 的 RMSNorm（modeling_qwen3.py:229-230, 244-245）：

$$q = q_norm(W_q\ x),\ k = k_norm(W_k\ x)$$

$$q,k = RoPE(q,k;\theta=10^6)$$

$$Attn(Q,K,V)=softmax((QK^{\top})/(\sqrt{(128)})+mask)V$$

注意力缩放固定为 head_dim**-0.5 = 128^-0.5（modeling_qwen3.py:213），不随 hidden 变。QK-Norm 稳定了逐头的分数幅度。

4.3 ③ GQA 与 KV 压缩

八档 KV 头数：Dense 0.6B–32B 一律 8 个 KV 头（Q 头数 16/16/32/32/40/64），MoE 两档 4 个 KV 头（32/64 个 Q 头）。运行时 num_key_value_groups = Q 头/KV 头用 repeat_kv 把 K/V 复制到 Q 头数。

4.4 ④ MoE 路由（128 专家选 8，无共享专家）

Qwen3MoeSparseMoeBlock（modeling_qwen3_moe.py:269-280）= Qwen3MoeTopKRouter（线性打分 → softmax → top-8，归一化权重）+ Qwen3MoeExperts（每专家一份融合的 gate_up / down 参数）：

```
router_logits = x @ W_gate^T                        # (seq, 128)
probs = softmax(router_logits, fp32)                # model:259-260
top_w, top_idx = topk(probs, k=8)                   # model:261
top_w = top_w / top_w.sum(-1, keepdim=True)         # 归一化 model:263
# 按专家桶分 token，各自 SwiGLU 后按 top_w 加权合并 model:229-245
```

config 侧： num_experts=128 、 num_experts_per_tok=8 、 moe_intermediate_size 30B-A3B=768 / 235B=1536、decoder_sparse_step=1（每层都走专家）； 无共享专家字段。对照 Qwen3.5 MoE 显式带 shared_expert_intermediate_size=512（演进章）。

5 注意力机制：全注意力 · RoPE 1e6 · 无滑窗

5.1 GQA KV 头分配

尺寸	Q 头数	KV 头数	GQA 分组	head_dim	Q 投影输出维
0.6B / 1.7B	16	8	2:1	128	2048
4B / 8B	32	8	4:1	128	4096
14B	40	8	5:1	128	5120
32B	64	8	8:1	128	8192
30B-A3B	32	4	8:1	128	4096
235B-A22B	64	4	16:1	128	8192

5.2 与 Qwen2/Qwen2.5 的注意力差异

Qwen2/Qwen2.5: `sliding_window=4096`（或 `32768`）+ `max_window_layers`，滑动窗口因果掩码

Qwen3: `sliding_window=null, use_sliding_window=false` → 全因果注意力

新增逐头 `q_norm/k_norm`（`head_dim` 维 `RMSNorm`）

`head_dim` 显式写进 `config`（`=128`），不再由 `hidden/heads` 隐式决定

源码：modeling_qwen3.py:231 仅当 layer_type==“sliding_attention” 才把 sliding_window 赋给注意力；qwen3 的 config 没有 layer_types 字段（hasattr(config,“layer_types”) 为 False，208 行），故全部层走全注意力。

6 多模态：Qwen3-VL 视觉塔与 early fusion

6.1 视觉塔 config（本地 3-VL-2B 逐字段核对）

字段（vision_config）	取值	字段	取值
model_type	qwen3_vl（视觉子模型）	hidden_size	1024
depth（视觉层数）	24	num_heads	16
intermediate_size	4096	hidden_act	gelu_pytorch_tanh
patch_size	16	temporal_patch_size	2
spatial_merge_size	2	out_hidden_size	2048（=文本 hidden）
deepstack_visual_indexes	[5, 11, 17]	num_position_embeddings	2304

文本塔侧（text_config）：hidden 2048 · 28 层 · 16Q/8KV · head_dim 128 · inter 6144 · vocab 151936 · max_position 262144 · rope_theta 5e6，且 rope_scaling.mrope_interleaved=true、mrope_section=[24,20,20]（M-RoPE：对时间/高度/宽度三个维度分别分配旋转维度）。

6.2 图像 token 流（patch 16 → merge 2 → early fusion）

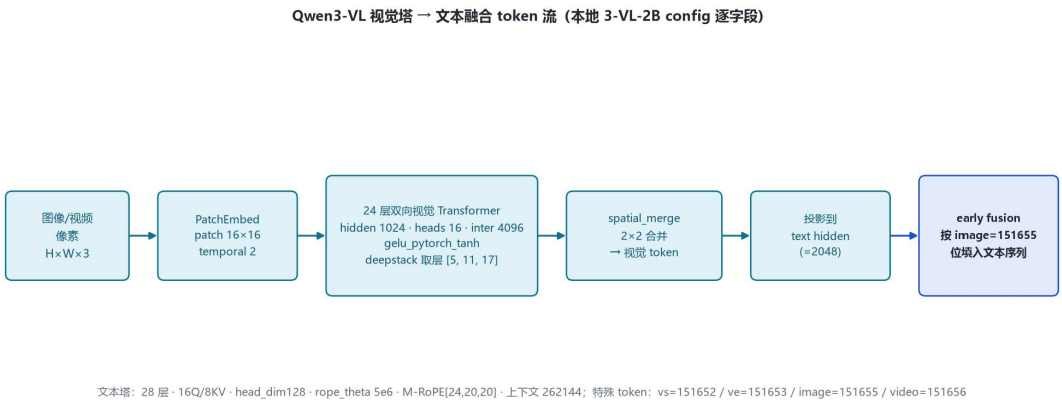


图 3：架构图：Qwen3-VL 视觉塔 → 文本融合 token 流

```
pixel_values (B,3,H,W)
  → PatchEmbed: patch 16×16、temporal_patch 2，切块
  → 24 层双向视觉 Transformer（deepstack 在第 5/11/17 层取特征）
  → spatial_merge_size=2：2×2 相邻 patch 合并为 1 个视觉 token
  → 投影到 out_hidden_size=2048（文本 hidden）
  → 按 <image> 占位（image_token_id=151655）位置 early-fusion 进文本序列
  → 与文本 token 一起过 28 层文本解码器（M-RoPE 给图像块空间/时间位置）
```

特殊 token：vision_start=151652、vision_end=151653、image=151655、video=151656（顶层 config）。transformers v5 里此类多模态模型用 AutoModelForImageTextToText 加载（AutoModelForVision2Seq 已移除）。

7 特殊 Token 与词表布局

token	ID	含义	来源		
bos_token_id	151643	<	im_start	> 会话开始	文本 config
eos_token_id	151645	<	im_end	> / 序列结束	文本 config
思维标记	<think> </think>	thinking 块（文本内编码，非离散 special id）	官方 model card		

token	ID	含义	来源		
软切换指令	/think /no_think	用户/系统消息内文本指令	官方 quickstart		
vision_start / vision_end	151652 / 151653	图像块起止（3-VL 顶层）	本地 3-VL config		
image / video token	151655 / 151656	图像/视频占位（3-VL 顶层）	本地 3-VL config		

词表 vocab_size=151936（Qwen1–Qwen3 沿用同一词表，3.5 起扩到 248320，见演进章）。思维块不是新增 special token，而是输出序列里的普通文本标记——这使 thinking 模式可与普通对话流无缝混用。

8 演进视角：Qwen2.5 → Qwen3

维度	Qwen2.5（基线）	Qwen3（家族）
推理行为	无原生思维	原生 thinking（enable_thinking 默认开 + /think /no_think 软切换）
注意力	GQA + 滑窗（sliding_window 4096 + max_window_layers）	回归全注意力（sliding_window=null），新增逐头 Q/K RMSNorm
head_dim	由 hidden/heads 隐式决定	显式 head_dim=128
MoE	Qwen2-MoE 57B-A14B（细粒度专家）	两档 MoE：30B-A3B / 235B-A22B，均 128 专家选 8, decoder_sparse_step=1
上下文（文本基座）	32768	40960（文本 config）；3-VL 扩到 262144
视觉塔	2.5-VL：patch 14、M-RoPE、128K	3-VL：patch 16、text rope_theta 5e6、M-RoPE [24,20,20]、262144
词表	151936	151936（不变）
MTP / 变体	无 MTP	MTP（qwen3_next）、3-ASR、3-Omni-MoE

Qwen3 的主线升级：① 原生 thinking 模式与软切换；② 注意力回归全注意力并加 QK-Norm；③ MoE 两档（128 选 8，无共享专家）；④ 3-VL 视觉塔 patch 14→16、文本 RoPE theta 提到 5e6、上下文到 262144；⑤ MTP 投机解码与 ASR/Omni 变体。Qwen2.5 侧数字为官方公开口径；Qwen3 侧数字均来自本页 config 与源码。

9 来源

1. 本地权威 config（Qwen3-0.6B，逐字段核对）

E:\models\qwen\Qwen3-0.6B\config.json （hidden 1024 / 28 层 / 16Q·8KV / head_dim 128 / inter 3072 / vocab 151936 / max 40960 / sliding null / ropeθ1e6 / tie=true）

2. 本地权威 config（Qwen3-VL-2B-Instruct，逐字段核对）

E:\models\qwen\Qwen3-VL-2B-Instruct\config.json （text: hidden 2048 / 28 层 / 16Q·8KV / head_dim 128 / inter 6144 / max 262144 / ropeθ5e6 / mrope[24,20,20]；vision: hidden 1024 / depth 24 / heads 16 / inter 4096 / patch 16 / temporal 2 / spatial_merge 2 / out 2048 / deepstack[5,11,17]）

3. 官方 config 经 hf-mirror 拉取（2026-10-26 逐字段核对，存 qwen3_tools_cfgpull\）

Qwen3-1.7B （2048/28/16Q·8KV/inter6144）；Qwen3-4B（2560/36/32Q·8KV/inter9728/tie）；Qwen3-8B（4096/36/32Q·8KV/inter12288/untie）；Qwen3-14B （5120/40/40Q·8KV/inter17408）；Qwen3-32B（5120/64/64Q·8KV/inter25600）；Qwen3-30B-A3B （2048/48/32Q·4KV/128 专家选 8/moe_inter768）；Qwen3-235B-A22B（4096/94/64Q·4KV/128 选 8/moe_inter1536）

4. transformers 源码（本地 E:\transformers\src\transformers\models\）

qwen3\modeling_qwen3.py ： RMSNorm 49-66 ； SwiGLU MLP 69-83 ； RotaryEmbedding 85-200；Attention 203-272（q/k_norm 229-230、scaling 213、repeat_kv 212）；DecoderLayer 275-315；ForCausalLM 423-495

qwen3_moe\modeling_qwen3_moe.py： Experts 209-246； TopKRouter 248-266； SparseMoeBlock 269-280；DecoderLayer 304-347

qwen3_vl\、qwen3_next\、qwen3_asr\、qwen3_omni_moe\（类入口与模块结构）

5. Qwen3 技术报告（arXiv 2505.09388）

https://arxiv.org/abs/2505.09388 （MoE 两档 48/94 层、128 选 8； Dense 六档；strong-to-weak 蒸馏）

6. Qwen3 官方博客

https://qwenlm.github.io/blog/qwen3/ （thinking 模式、/think 与 /no_think 软切换、enable_thinking、各档层数/头数/上下文对照表）

7. Qwen 官方文档 quickstart（软切换口径）

https://qwen.readthedocs.io/en/stable/getting_started/quickstart.html （ /think 与 /no_think 多轮跟随最近指令）

8. Qwen3-VL 技术报告（arXiv 2511.21631）

https://arxiv.org/pdf/2511.21631 （3-VL 家族 2B/4B/8B/32B Dense + 30B-A3B/235B-A22B MoE）

标注约定：[S:n]=modeling 文件行号。3-VL 4B/8B/32B 的 exact hidden/inter 沿用对应 Dense 文本塔（官方 model card），本地未逐一拉取 config；MoE 无共享专家系以本地 config 字段为准（官方 30B-A3B/235B config 无 shared_expert 字段）。访问与核验日期：2026-10-26。

页脚：Qwen 3 家族架构详解 · 数据来源：本地/hf-mirror config + transformers 源码 + arXiv 2505.09388 / 2511.21631 / Qwen 官方资料 · 仅供技术学习与论文研究