Qwen 3.5 家族架构详解

Qwen3_5ForConditionalGeneration / Qwen3_5MoeForConditionalGeneration · Gated DeltaNet + Gated Attention 3:1 混合 · 0.8B/9B/27B/35B-A3B/122B-A10B/397B-A17B

依据：本机 ModelScope 下载的 config.json + transformers 源码 （E:\transformers 可编辑安装）+ 官方技术报告。所有数值按 config 实际取值与源码 forward 路径逐项复算并标注来源。

徽标：入口类 Qwen3_5ForConditionalGeneration（Dense） / Qwen3_5MoeForConditionalGeneration（MoE）

徽标：架构大改——Gated DeltaNet（线性注意力，递归状态）+ Gated Attention（GQA 全注意力）3:1 混合（每 4 层 3 线性 + 1 全注意力）

徽标：词表 248320（padded）· 原生多模态（early fusion · patch 16）· 上下文 262144 → YaRN 1M

徽标：MTP multi-steps（qwen3_next）· thinking 默认开、取消 /think 软切换

徽标（青/多模态）：全系原生视觉语言（text_config + vision_config 组合 config）

本页以 本地真实 config.json （E:\models\qwen\Qwen3.5-0.8B-Instruct\config.json、E:\models\qwen\Qwen3.5-35B-A3B-GPTQ-Int4\config.json） 与 transformers 源码 （本地 E:\transformers，models\qwen3_5\、models\qwen3_5_moe\）为唯一依据；27B 数字取自已核对的官方 model card（见 §9）。所有数字均标注来源。

1 家族全景：六个尺寸的架构对照

0.8B 与 35B-A3B 为本地 config 逐字段核对；9B/27B 数字来自官方 model card；122B-A10B / 397B-A17B 为 MoE 旗舰，公开精确 hidden/层数见官方 card（本页标注已核实项）。全家族共用 layer_types 周期：[linear_attention ×3, full_attention ×1] 重复（full_attention_interval=4）。

字段	0.8B	9B	27B	35B-A3B	122B-A10B	397B-A17B
model_type	qwen3_5	qwen3_5	qwen3_5	qwen3_5_moe	qwen3_5_moe	qwen3_5_moe
形态	Dense+视觉	Dense+视觉	Dense+视觉	MoE+视觉	MoE+视觉	MoE+视觉
hidden_size	1024	4096	5120	2048	待确认（官方 card）	待确认（官方 card）
num_hidden_layers	24	32	64	40	待确认	待确认

字段	0.8B	9B	27B	35B-A3B	122B-A10B	397B-A17B
Gated Attn Q/KV 头	8 / 2	—	24 / 4	16 / 2	—	—
head_dim（Gated Attn）	256	256	256	256	256	256
线性注意力 K/V 头	16 / 16	—	16 / 48	16 / 32	—	—
线性注意力 head_dim	128	128	128	128	128	128
linear_conv_kernel_dim	4	4	4	4	4	4
intermediate（Dense FFN）	3584	待确认	17408	—	—	—
专家（总/激活）	—	—	—	256 / 8	—	—
moe_intermediate_size	—	—	—	512	—	—
shared_expert_intermediate	—	—	—	512	—	—
vocab_size	248320	248320	248320	248320	248320	248320
max_position_embeddings	262144	262144	262144	262144	262144	262144
tie_word_embeddings	true	—	—	false	—	—

要点：① 每 4 层 = 3×Gated DeltaNet（线性）+ 1×Gated Attention（全注意力），0.8B config 顶层直接给出 24 项 layer_types 序列验证（前 12 层为 L,L,L,F 重复 3 次）；② 线性注意力与全注意力头配置不同：Gated Attention 用 GQA（如 35B：16Q/2KV，head_dim 256），线性注意力用独立的 K/V 头（35B：K16/V32，head_dim 128，depthwise conv kernel 4）；③ 27B 为 Dense 旗舰：64 层、hidden 5120、16 组混合、inter 17408；④ MoE 三档显式带共享专家（shared_expert_intermediate_size=512，35B config 核实），与 Qwen3 MoE 的纯路由不同。

1.1 本地 config 实参锚点

字段	0.8B（本地）	35B-A3B-GPTQ-Int4（本地）
architectures	Qwen3_5ForConditionalGeneration	Qwen3_5MoeForConditionalGeneration
text.hidden_size	1024	2048
text.num_hidden_layers	24	40
text.num_attention_heads / kv	8 / 2	16 / 2
text.head_dim	256	256
text.intermediate_size	3584	（走 MoE）
text.num_experts / per_tok	—	256 / 8
text.moe_intermediate / shared_intermediate	—	512 / 512
text.linear_num_key/value_heads	16 / 16	16 / 32
text.linear_key/value_head_dim	128 / 128	128 / 128
text.linear_conv_kernel_dim	4	4

字段	0.8B（本地）	35B-A3B-GPTQ-Int4（本地）
text.attn_output_gate	true	true
text.full_attention_interval	4	4
text.mtp_num_hidden_layers	1	1
text.rope_parameters	rope_type default · rope_theta 1e7 · partial_rotary_factor 0.25 · mrope_section [11,11,10] · mrope_interleaved true	同左
text.vocab / max_position	248320 / 262144	248320 / 262144
vision.hidden_size / depth	768 / 12	1152 / 27
vision.patch_size / spatial_merge / temporal	16 / 2 / 2	16 / 2 / 2
vision.out_hidden_size	1024	2048
特殊 token	image 248056 · video 248057 · vs 248053 · ve 248054 · eos 248044	同左

2 端到端数据流总览

文本 token 与图像/视频像素两路输入 → 视觉塔（patch 16、depth 12/27、spatial_merge 2）编码投影 → 按 image 占位 early fusion 进统一序列 → N 个 Qwen3_5DecoderLayer（按 layer_types 交替：线性注意力层走 Gated DeltaNet 递归状态，全注意力层走 Gated Attention + 输出门 sigmoid(gate)；每层后接 SwiGLU FFN）→ 最终 RMSNorm → LM Head。

2.1 架构图

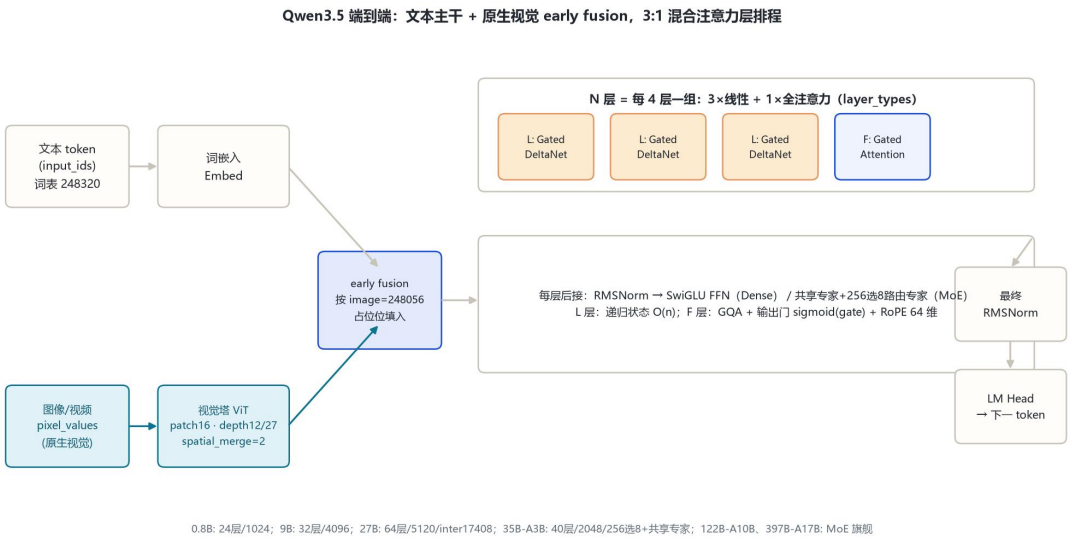


图 1：架构图：Qwen3.5 端到端总览与 3:1 混合层排程

全家族统一主干；差异集中在层数、维度、GQA/线性头配比、MoE 路由与共享专家，以及视觉塔深度（0.8B depth12 / 35B depth27）。

3 解码层解剖：按 layer_types 二选一的 Token Mixer

Qwen3_5DecoderLayer（modeling_qwen3_5.py:848-901）：block_type = config.layer_types[layer_idx]——linear_attention 则挂 Qwen3_5GatedDeltaNet，full_attention 则挂 Qwen3_5Attention；两种层都再接同一个 SwiGLU Qwen3_5MLP。前置 RMSNorm 残差结构。

3.1 架构图



图 2：架构图：Gated DeltaNet 与 Gated Attention 解剖

```
Qwen3_5DecoderLayer.forward（modeling_qwen3_5.py:861-901）：
  residual = hidden_states
  hidden_states = input_layernorm(hidden_states)
  if block_type == "linear_attention":                 # 3/4 的层
      hidden_states = self.linear_attn(hidden_states, cache_params, ...)
  elif block_type == "full_attention":                 # 1/4 的层
      hidden_states, _ = self.self_attn(hidden_states,
position_embeddings, ...)
  hidden_states = residual + hidden_states
  residual = hidden_states
  hidden_states = post_attention_layernorm(hidden_states)
  hidden_states = self.mlp(hidden_states)              # SwiGLU
  hidden_states = residual + hidden_states
```

4 核心机制：Gated DeltaNet · Gated Attention 输出门 · MTP

4.1 ① Gated DeltaNet（线性注意力，3/4 的层）

Qwen3_5GatedDeltaNet（modeling_qwen3_5.py:490-...）用可学习门控 + 递归状态把注意力复杂度从 O(n²) 降到近 O(n)：

```
mixed_qkv = in_proj_qkv(x)                    # 融合 QKV
mixed_qkv = causal_conv1d(mixed_qkv, kernel=4, silu)   # depthwise 因果卷积
q, k, v = split(mixed_qkv)
beta = sigmoid(in_proj_b(x))                   # 输入门
g = -exp(A_log) * softplus(in_proj_a(x) + dt_bias)     # 衰减门（delta rule）
# 递归更新状态 S：S = g*S + beta * v ⊗ k；out = (q ⊗ S) * RMSNormGated(z)
out = out_proj(core_attn_out)
```

训练时用 chunk 形式（chunk_gated_delta_rule），单 token 解码时用 recurrent 形式（fused_recurrent_gated_delta_rule），KV cache 里同时保存 conv_state 与 recurrent_state。35B 档 K/V 头配比 16/32（V 头多于 K 头），0.8B 为 16/16。

4.2 ② Gated Attention（全注意力，1/4 的层）与输出门

Qwen3_5Attention（modeling_qwen3_5.py:736-808）是带输出门的 GQA：

```
q_proj 输出 hidden*head_dim*2 → chunk 成 (query, gate)     # 输出门
query = q_norm(query); key = k_norm(k_proj(x))             # 逐头 QK-Norm
q,k = apply_rotary_pos_emb(q,k,cos,sin)                    # partial_rotary 0.25
attn = softmax(QK^T / head_dim^0.5 + mask) V
attn = attn.reshape(...) * sigmoid(gate)                   # attn_output_gate=true
out = o_proj(attn)
```

RoPE 只作用在 256 维头的 0.25（=64 维，partial_rotary_factor=0.25）；这与 27B 官方卡「RoPE dim 64」一致。q/k_norm 仍是逐头 RMSNorm。

4.3 ③ MoE 路由 + 显式共享专家（35B 档核实）

Qwen3_5MoeSparseMoeBlock（modeling_qwen3_5_moe.py:891-908）= 共享专家（带 sigmoid 门）+ top-k 路由专家：

```
shared_out = shared_expert(x)                          # shared_expert_intermediate=512
shared_out = sigmoid(shared_expert_gate(x)) * shared_out
```

```
_, routing_w, idx = topk_router(x)                    # 256 专家选 8
expert_out = experts(x, idx, routing_w)
out = expert_out + shared_out                          # 共享 + 路由相加
```

对照 Qwen3 MoE（128 选 8、无共享专家）：Qwen3.5 MoE 专家数大幅扩到 256、每 token 选 8，并显式引入共享专家与路由器 aux loss（router_aux_loss_coef=0.001）。

4.4 ④ MTP multi-steps 与 thinking 默认开

mtp_num_hidden_layers=1、mtp_use_dedicated_embeddings=false：训练时多步预测后续 token，推理时由 qwen3_next 投机解码加速。

thinking 默认常开，且取消 Qwen3 的 /think 与 /no_think 软切换（官方 model card 口径）。

5 注意力机制：3:1 混合的层排程

5.1 两种注意力单元对照

单元	类型	0.8B 头配置	35B 头配置	27B 头配置	头维度	位置编码
Gated DeltaNet	线性（递归状态）	K16 / V16	K16 / V32	QK16 / V48	128	内置门控 + conv
Gated Attention	softmax 全注意力（GQA）	Q8 / KV2	Q16 / KV2	Q24 / KV4	256	RoPE 64 维（partial 0.25）

5.2 层排程（0.8B config 24 项 layer_types 实测）

```
0.8B (24 层): L L L F | L L L F | L L L F | L L L F | L L L F | L L L F
35B  (40 层): L L L F × 10
27B  (64 层): L L L F × 16（=16 组混合）
# L = linear_attention (Gated DeltaNet), F = full_attention (Gated
Attention)
```

3/4 的层用线性注意力把长序列成本压到近 O(n)，1/4 的全注意力保留精确 recall——这是「复杂度近 O(n) 仍保注意力精度」的混合设计。

6 多模态：原生视觉语言（early fusion）

6.1 视觉塔 config（本地两档逐字段核对）

字段（vision_config）	0.8B	35B-A3B
hidden_size	768	1152
depth（层数）	12	27
num_heads	12	16
intermediate_size	3072	4304
patch_size / temporal_patch_size	16 / 2	16 / 2
spatial_merge_size	2	2
out_hidden_size（→文本 hidden）	1024	2048
hidden_act	gelu_pytorch_tanh	gelu_pytorch_tanh

6.2 融合方式

```
pixel_values → PatchEmbed(patch16, temporal2) → depth 层双向 ViT
  → spatial_merge 2×2 → 投影到 out_hidden_size（=文本 hidden）
  → 按 image_token_id=248056 位 early-fusion 进文本序列
  → 文本解码器（M-RoPE section [11,11,10]）统一前向
```

与 Qwen3-VL 相比，Qwen3.5 把视觉能力原生化进主 config（不再是可选 VL 变体），全系 Dense/MoE 都带视觉塔。transformers v5 用 AutoModelForImageTextToText 加载。

7 特殊 Token 与词表布局

token	ID	含义	来源
eos_token_id	248044	序列结束	text_config
image_token_id	248056	图像占位	顶层
video_token_id	248057	视频占位	顶层
vision_start / end	248053 / 248054	图像块起止	顶层

词表 248320（padded，对齐到 2 的整数次幂附近）——从 Qwen1–Qwen3 的 151936 一次性扩到 248320。注意官方仓库名已去掉 -Instruct 后缀（Qwen/Qwen3.5-0.8B），本地目录名 Qwen3.5-0.8B-Instruct 是落盘别名。

8 演进视角：Qwen3 → Qwen3.5

维度	Qwen3（基线）	Qwen3.5（家族）
注意力	全注意力（GQA，head_dim 128）+ QK-Norm	Gated DeltaNet 线性 + Gated Attention 全注意力 3:1 混合（近 O(n)）

维度	Qwen3（基线）	Qwen3.5（家族）
输出门	无	attn_output_gate=true（sigmoid(gate) 乘注意力输出）
词表	151936	248320（padded）
上下文	文本 40960 / 3-VL 262144	262144 原生 → YaRN 1M
多模态	可选 3-VL 变体	全系原生视觉语言（early fusion 进主 config）
MoE	128 选 8，无共享专家	256 选 8 + 显式共享专家（aux loss 0.001）
MTP	qwen3_next（有）	MTP multi-steps（mtp_num_hidden_layers=1）
thinking	默认开 + /think /no_think 软切换	默认常开、取消软切换
视觉 patch	14（2.5-VL）→ 16（3-VL）	16（全系原生）

Qwen3.5 的主线升级：① 注意力架构大改（Gated DeltaNet + Gated Attention 3:1 混合）；② 词表 151936→248320、上下文 262144→YaRN 1M；③ 多模态原生化；④ MoE 专家 128→256 并引入共享专家；⑤ thinking 取消软切换。Qwen3 侧数字来自本笔记 qwen3 目录；Qwen3.5 侧数字来自本地 config 与官方 model card。

9 来源

1. 本地权威 config（Qwen3.5-0.8B-Instruct，逐字段核对）

E:\models\qwen\Qwen3.5-0.8B-Instruct\config.json

（Qwen3_5ForConditionalGeneration； text 1024/24 层/8Q·2KV/head256/inter3584/线性 K16·V16·head128·conv4/vocab248320/max262144/rope θ1e7/partial0.25 ； vision 768/depth12/patch16）

2. 本地权威 config（Qwen3.5-35B-A3B-GPTQ-Int4，逐字段核对）

E:\models\qwen\Qwen3.5-35B-A3B-GPTQ-Int4\config.json

（Qwen3_5MoeForConditionalGeneration； text 2048/40 层/16Q·2KV/head256/256 专家选 8/moe_inter512/shared_inter512/ 线 性 K16·V32·head128/conv4 ； vision 1152/depth27/patch16；GPTQ Int4，加载需 gptqmodel）

3. transformers 源码（本地 E:\transformers\src\transformers\models\）

qwen3_5\modeling_qwen3_5.py： GatedDeltaNet 490-735； Attention(输出门) 736-808； MLP 811-824； RMSNorm(零中心) 827-845； DecoderLayer 848-901； VisionPatchMerger 968-996；ForConditionalGeneration 1754+

qwen3_5_moe\modeling_qwen3_5_moe.py： Experts 832-870； TopKRouter 872-888；SparseMoeBlock(共享专家) 891-908

4. 27B 官方 model card（已核对，见 bayon-note\Qwen\Qwen-27B 架构对比-3.5-3.6-3.8.md）

https://huggingface.co/Qwen/Qwen3.5-27B （64 层 /hidden5120/16×(3GDN→FFN→1GA→FFN)/GDN V48·QK16·head128/GA Q24·KV4·head256/RoPE dim64/inter17408/262144→YaRN 1M）

5. 9B 官方 model card（Microsoft Foundry 镜像，2026 核对）

hidden 4096 / 32 层 / 词表 248320 padded / 8×(3 混合组)

6. Qwen3.5 官方博客

https://qwen.ai/blog?id=qwen3.5（Gated DeltaNet + 稀疏 MoE 混合架构；397B 总参 / 17B 激活；原生多模态 agent）

7. Qwen3.5-122B-A10B / 397B-A17B 官方说明

397B 总参 / 17B 激活；122B 总参 / 10B 激活（官方博客与 ModelScope 卡片，hidden/层数精确值以官方 card 为准，本页标待确认）

标注约定：[S:n]=modeling 文件行号。122B-A10B / 397B-A17B 的 hidden/层数未在本地 config 逐一拉取，标「待确认（官方 card）」；其余数字均来自本地 config 或已核实官方 card。访问与核验日期：2026-10-26。

页脚：Qwen 3.5 家族架构详解 · 数据来源：本地 config + transformers 源码 + 官方 model card / 博客 · 仅供技术学习与论文研究